UNIVERSIDAD DEL BÍO-BÍO

FACULTAD DE CIENCIAS

DEPARTAMENTO DE ESTADÍSTICA

MAGÍSTER EN ESTADÍSTICA

Análisis del S&P 500 mediante RIDGE

Una aplicación de regresión por componentes principales

Autor

Vargas Jiménez, Fabián Oscar Andrés

Curso

Métodos alternativos de regresión

Profesor guía

Dr. Firinguetti Limone, Luis Alberto

Concepción, octubre 2026

Índice general

1. Introducción **1**

1.0.1. Regularización en problemas financieros de alta dimensión 2

1.0.2. Predicción de rendimientos y seguimiento de índices 3

1.0.3. Información macroeconómica, regímenes y estabilidad 4

1.1. Planteamiento del problema 5

1.2. Pregunta de investigación 6

1.2.1. Preguntas específicas 6

1.3. Objetivos 7

1.3.1. Objetivo general 7

1.3.2. Objetivos específicos 7

1.4. Hipótesis de investigación 8

2. Metodología **9**

2.1. Limpieza de la base de precios 9

2.2. Construcción de las variables 10

2.3. Especificación de la regresión ridge 10

2.4. Partición cronológica y validación temporal 11

2.5. Ajuste final y evaluación fuera de muestra 12

2.6. Diagnóstico de residuos 13

3. Datos **14**

3.1. Fuentes de información y período de estudio 14

3.2. Limpieza y tratamiento 15

3.2.1. Patrón de los datos faltantes 15

3.2.2. Cobertura individual y conjunta 16

3.2.3. Tratamiento del valor faltante de FISV 17

3.2.4. Base de Datos Limpia 17

3.3. Análisis descriptivo 17
3.3.1. Distribución transversal de los rendimientos 17
3.3.2. Indicador equiponderado 18
3.3.3. Evolución anual 20
3.3.4. Distribución y jornadas atípicas 20
3.3.5. Rendimiento, volatilidad y riesgo empresarial 21
3.3.6. Estructura de correlaciones 21

4. Resultados **23**
4.1. Muestra utilizada en la estimación 23
4.2. Presentación gráfica de los resultados 24
4.3. Selección del parámetro de regularización 24
4.4. Desempeño dentro y fuera de muestra 25
4.5. Diagnóstico de residuos 27
4.6. Coeficientes del modelo ridge 29

5. Limitaciones **31**
5.1. Composición histórica y calidad de los datos 31
5.2. Alcance y construcción del índice 31
5.3. Validación temporal y comparación de modelos 32
5.4. Inferencia y estructura de los residuos 32

6. Conclusiones **33**

A. Listado de empresas del S&P 500 **36**

B. Distribución de empresas por sector económico **51**

C. Material gráfico complementario **52**
C.1. Distribución de los rendimientos 52
C.2. Autocorrelación de los residuos 54

Resumen

El índice S&P 500 resume el comportamiento de una parte significativa del mercado accionario estadounidense y se construye a partir de empresas cuyos rendimientos presentan dependencias comunes de mercado y sector. Esta investigación evalúa la capacidad de la regresión ridge para reproducir fuera de muestra el rendimiento diario contemporáneo del índice utilizando los rendimientos de sus empresas componentes. La regularización se emplea para estabilizar la estimación ante un número elevado de predictores y una estructura de correlaciones potencialmente problemática.

La base original comprendió 503 empresas y 1 435 jornadas bursátiles entre enero de 2021 y septiembre de 2026. Después de examinar la cobertura temporal, se excluyeron quince empresas con series parciales y se corrigió una omisión puntual verificada para FISV. Tras transformar los precios ajustados en rendimientos logarítmicos y alinear las fechas con el índice, el modelo utilizó 1 434 observaciones y 487 predictores. Las observaciones se dividieron cronológicamente: el primer 80 % se destinó al entrenamiento y el 20 % final a la prueba.

El parámetro de penalización se seleccionó mediante validación temporal de origen móvil con cinco bloques. Se evaluaron 200 valores de λ y se adoptó la regla de un error estándar, que produjo $\lambda_{1\mathrm{SE}} = 0{,}0016831804$. En la muestra de prueba, ridge alcanzó un MSE de $7{,}7127 \times 10^{-6}$, un RMSE de 0,0027772, un MAE de 0,0020622, un R^2 de 0,8781 y una correlación de 0,9396. Frente a una referencia basada en la media del entrenamiento, el modelo redujo el MSE en 87,82 %.

Los resultados muestran una elevada capacidad de seguimiento contemporáneo fuera de muestra. Sin embargo, los residuos presentan colas pesadas, autocorrelación lineal leve en prueba y dependencia temporal en su magnitud, por lo que los resultados deben interpretarse en términos predictivos y no como base para inferencia clásica. Además, el modelo no reproduce la ponderación oficial del índice ni demuestra capacidad para anticipar rendimientos futuros, pues la respuesta y los predictores corresponden a la misma jornada.

Palabras clave: regresión ridge; regularización; S&P 500; seguimiento de índices; multicolinealidad; validación temporal; rendimientos bursátiles.

Capítulo 1

Introducción

Los índices bursátiles son referencias fundamentales para describir los mercados y diseñar estrategias de inversión pasiva. El S&P 500 ocupa una posición central porque reúne empresas de gran capitalización pertenecientes a diversos sectores de la economía estadounidense. Reproducir su comportamiento a partir de cientos de componentes plantea, sin embargo, un problema de alta dimensión: los rendimientos empresariales comparten factores de mercado y sectoriales, por lo que existe información redundante y multicolinealidad.

La regresión ridge aborda esta dificultad mediante una penalización cuadrática que contrae los coeficientes, reduce la variabilidad de la estimación y conserva todos los predictores. La intensidad de la contracción depende de λ, cuyo valor debe seleccionarse sin utilizar las observaciones reservadas para evaluar el desempeño final.

Este estudio evalúa si ridge permite reproducir fuera de muestra el rendimiento diario contemporáneo del S&P 500 a partir de los rendimientos de sus empresas componentes. Para ello se limpia una base de precios ajustados, se calculan rendimientos logarítmicos y se divide la muestra cronológicamente en entrenamiento y prueba. El parámetro λ se selecciona dentro del entrenamiento mediante validación temporal de origen móvil y la regla de un error estándar.

El análisis mide asociación contemporánea y capacidad de seguimiento, no pronóstico financiero, porque la respuesta y los predictores corresponden a la misma jornada. Los resultados muestran una elevada capacidad de réplica fuera de muestra y un desempeño superior al de la referencia basada en la media del entrenamiento. La pertinencia del enfoque se examina a continuación mediante la literatura sobre regularización financiera, seguimiento de índices y evaluación fuera de muestra.

1.0.1. Regularización en problemas financieros de alta dimensión

La estimación financiera con un número elevado de activos enfrenta dos dificultades estrechamente relacionadas: la fuerte correlación entre los predictores y la inestabilidad de los parámetros estimados. En aplicaciones de carteras, pequeñas perturbaciones en los rendimientos o en la matriz de covarianzas pueden traducirse en cambios importantes en las ponderaciones. Este problema se vuelve especialmente relevante cuando el número de activos es grande en relación con la cantidad de observaciones disponibles. En este contexto, la regularización introduce sesgo de manera deliberada para reducir la varianza del estimador y estabilizar la solución.

La regresión ridge materializa este principio mediante una penalización cuadrática sobre los coeficientes. Al conservar todos los predictores y contraer conjuntamente sus coeficientes, resulta particularmente apropiada cuando las variables presentan correlaciones elevadas y la señal se distribuye entre numerosos activos. Esta característica es pertinente para el seguimiento de un índice bursátil, porque los rendimientos de las empresas que lo integran comparten factores de mercado y sectoriales y, por consiguiente, contienen información redundante.

La literatura reciente confirma que la regularización no solo es un recurso numérico, sino también una herramienta para controlar el riesgo de estimación. Gehrig, Sögner y Westerkamp[5] incorporan un mecanismo de contracción en políticas paramétricas de cartera, llevando las ponderaciones hacia una cartera de referencia. Utilizando acciones estadounidenses, muestran que las estrategias regularizadas mejoran el desempeño fuera de muestra de las políticas paramétricas y de la estrategia ingenua $1/N$ para un rango amplio de niveles de aversión al riesgo. El resultado respalda la idea de que una solución deliberadamente contraída puede ser preferible a una estimación más flexible, pero altamente variable.

Desde una perspectiva complementaria, Doukali, Kone y Taamouti[3] estudian la selección de carteras grandes cuando existen asimetrías tanto en los rendimientos como en las actitudes frente al riesgo. El problema requiere invertir una matriz de covarianzas que puede ser casi singular cuando la dimensión es elevada. Los autores comparan regularización ridge, corte espectral, Landweber–Fridman y regresiones nodewise con penalización lasso, junto con procedimientos de selección de los parámetros de ajuste. Sus simulaciones y aplicaciones empíricas muestran que regularizar la matriz de precisión produce carteras más estables, con menor rotación y mejores razones de Sharpe y de Sharpe generalizada que varias estrategias de referencia. Esta evidencia es consistente con el propósito de ridge: moderar la sensibilidad de la solución ante direcciones débilmente identificadas.

1.0.2. Predicción de rendimientos y seguimiento de índices

La aplicación más cercana al presente proyecto es el seguimiento de índices mediante combinaciones lineales de acciones. Ding et al.[2] proponen el *arbitrary rectangle-range generalized elastic net* (ARGEN), una familia que combina penalizaciones tipo lasso y ridge con restricciones inferiores y superiores sobre los coeficientes. En su aplicación al seguimiento del S&P 500, separan los datos en entrenamiento, validación y prueba, seleccionan los hiperparámetros mediante el error cuadrático medio de validación y evalúan posteriormente el desempeño fuera de muestra. Los resultados indican que las versiones regularizadas y restringidas reducen el error de seguimiento y la volatilidad frente a especificaciones menos flexibles, aunque reconocen que una mayor cantidad de activos aumenta el costo computacional. Este antecedente sustenta tanto el uso de una función de pérdida cuadrática como la necesidad de reservar observaciones que no participen en la selección del parámetro de regularización.

La evidencia predictiva, sin embargo, aconseja no interpretar la regularización como una garantía automática de buen desempeño. Scholz[10] analiza combinaciones de pronósticos para rendimientos de largo plazo del S&P 500 entre 1872 y 2022. Aunque incluye lasso, ridge y elastic net entre los métodos de combinación, encuentra que las combinaciones con un conjunto amplio de candidatos pueden sobreajustarse dentro de muestra y deteriorarse considerablemente fuera de ella. La restricción a modelos de menor dimensión mejora el equilibrio entre ajuste y generalización, pero los modelos no paramétricos individuales continúan mostrando mejores resultados en varios ejercicios. Por ello, la complejidad del modelo debe justificarse mediante evaluación fuera de muestra y comparación con referencias sencillas.

Una conclusión similar surge de estudios que comparan múltiples algoritmos. Chun, Kang y Kim[1] utilizan 137 variables financieras y económicas para pronosticar el tipo de cambio KRW/USD y los rendimientos de los mercados estadounidense y coreano. Ridge mejora ligeramente algunos resultados frente a mínimos cuadrados y ciertos modelos tradicionales, pero lasso y elastic net obtienen la mayor precisión predictiva y los mejores resultados de cartera. En la cartera estadounidense, por ejemplo, ridge alcanza una razón de Sharpe anualizada de 0,563, cercana a la inversión pasiva en el S&P 500, mientras que lasso y elastic net alcanzan 0,855 y 0,894, respectivamente. Esto muestra que ridge constituye una referencia regularizada pertinente, aunque su desempeño debe establecerse empíricamente y no suponerse de antemano.

Asimismo, Ha et al.[6] evalúan estrategias dinámicas para una cartera *all-weather* compuesta por fondos cotizados que representan al S&P 500, bonos del Tesoro de largo plazo

y oro. Con datos diarios entre diciembre de 2004 y julio de 2024, comparan regresiones penalizadas, árboles y redes neuronales. Lasso y elastic net presentan los mejores resultados globales para el S&P 500 y generan razones de Sharpe cercanas a 0,70, superiores al máximo de 0,58 obtenido por las estrategias estáticas analizadas. Los autores también advierten que los costos de transacción, las restricciones operativas y el sesgo derivado de ajustar hiperparámetros pueden reducir las ventajas observadas. Su diseño de validación secuencial refuerza la necesidad de preservar el orden temporal de los datos.

1.0.3. Información macroeconómica, regímenes y estabilidad

La relación entre regularización y estabilidad también aparece en modelos que incorporan estados de la economía. Oliveira et al.[7] construyen regímenes macroeconómicos mediante técnicas de agrupamiento aplicadas a la base FRED-MD y utilizan sus probabilidades de transición para orientar la asignación táctica. Al comparar carteras equiponderadas, optimización media–varianza, Black–Litterman y regresiones ridge, encuentran que las especificaciones ridge enriquecidas con información de régimen presentan el comportamiento más robusto en la mayoría de las métricas. La mejor configuración ridge alcanza una razón de Sharpe de 1,341, frente a 1,092 para la mejor especificación media–varianza y 0,406 para la cartera equiponderada. Los resultados también favorecen estrategias parsimoniosas y con restricciones de posiciones, lo que sugiere que la información adicional genera valor cuando se combina con mecanismos explícitos de estabilización.

En conjunto, estos estudios muestran que la utilidad de la regularización depende de tres elementos. Primero, debe existir un problema de varianza, multicolinealidad o inversión inestable que justifique la contracción. Segundo, el parámetro de penalización debe seleccionarse con datos distintos de aquellos empleados para evaluar definitivamente el modelo. Tercero, el resultado debe contrastarse fuera de muestra con referencias simples, porque una reducción del error de entrenamiento no implica una mejora de generalización.

En concordancia con esta evidencia, el presente estudio modela el rendimiento diario del S&P 500 como una función lineal de los rendimientos contemporáneos de sus empresas componentes. La elevada correlación transversal y el gran número de predictores justifican una solución que conserve la información disponible y distribuya la contracción entre variables relacionadas. El diseño separa cronológicamente la estimación, la selección de λ y la evaluación final, de modo que la estabilidad y el error de seguimiento se examinan fuera de muestra sin atribuir capacidad predictiva a una relación contemporánea.

1.1. Planteamiento del problema

El índice S&P 500 sintetiza el comportamiento de una parte sustantiva del mercado accionario estadounidense y se construye a partir de empresas que difieren en tamaño, sector económico, volatilidad y trayectoria bursátil. Aunque esta composición permite representar el movimiento agregado del mercado, también genera un problema estadístico cuando se pretende reproducir el rendimiento del índice mediante los rendimientos de sus componentes. El número de variables explicativas es elevado y existen correlaciones importantes entre ellas, debido a la exposición común a factores de mercado, sectoriales y macroeconómicos.

En este escenario, una regresión estimada mediante mínimos cuadrados ordinarios puede presentar coeficientes inestables. La multicolinealidad no necesariamente impide obtener un buen ajuste dentro de muestra, pero aumenta la sensibilidad de los coeficientes frente a pequeñas variaciones en los datos y puede deteriorar el desempeño fuera de muestra. Esta dificultad se intensifica cuando algunas empresas poseen historiales más breves, existen cambios en la composición del índice o la cantidad de predictores es grande en relación con el período efectivo de estimación.

La regresión ridge ofrece una alternativa al incorporar una penalización cuadrática que contrae los coeficientes y estabiliza la solución. Sin embargo, el grado de contracción depende del parámetro de regularización λ. Un valor demasiado pequeño aproxima el modelo a mínimos cuadrados y puede conservar su inestabilidad, mientras que un valor excesivo puede producir subajuste. En consecuencia, λ debe seleccionarse mediante un procedimiento que preserve el orden temporal de los datos y que mantenga separada la muestra destinada a evaluar el resultado final.

El problema de investigación consiste, por tanto, en determinar si una regresión ridge construida con los rendimientos diarios de las empresas del S&P 500 permite reproducir de manera estable el rendimiento diario contemporáneo del índice fuera de muestra. El interés no reside en anticipar el rendimiento del día siguiente, sino en evaluar la capacidad de seguimiento de una combinación lineal regularizada cuando los predictores son numerosos y están correlacionados. Para ello, el modelo debe compararse con una referencia sencilla y evaluarse mediante medidas de error, ajuste y asociación calculadas sobre observaciones que no hayan intervenido en la estimación ni en la selección de λ.

1.2. Pregunta de investigación

> ¿En qué medida una regresión ridge, cuyo parámetro de regularización se selecciona mediante validación temporal, permite reproducir fuera de muestra el rendimiento diario contemporáneo del índice S&P 500 a partir de los rendimientos de sus empresas componentes?

De manera complementaria, el estudio busca establecer si la contracción impuesta por ridge permite obtener un desempeño superior al de una referencia que predice constantemente la media del rendimiento observada en el conjunto de entrenamiento, y si dicho desempeño se mantiene cuando la evaluación se realiza sobre el tramo cronológicamente posterior reservado como muestra de prueba.

1.2.1. Preguntas específicas

1. ¿Qué características presentan la cobertura temporal, la distribución de los rendimientos y la estructura de correlación de las empresas utilizadas como predictores?

2. ¿Qué valor del parámetro de regularización λ se obtiene mediante validación temporal de origen móvil y cómo cambia la elección al aplicar la regla de un error estándar?

3. ¿Qué desempeño alcanza el modelo ridge dentro y fuera de muestra según el MSE, RMSE, MAE, R^2 y la correlación entre rendimientos observados y estimados?

4. ¿El modelo ridge supera fuera de muestra a la referencia que predice la media del rendimiento observada en el conjunto de entrenamiento?

5. ¿Qué muestran los diagnósticos residuales sobre autocorrelación, heterocedasticidad, normalidad y dependencia temporal de la volatilidad?

1.3. Objetivos

1.3.1. Objetivo general

Evaluar la capacidad de la regresión ridge para reproducir fuera de muestra el rendimiento diario contemporáneo del índice S&P 500 utilizando como predictores los rendimientos diarios de sus empresas componentes, con selección temporal del parámetro de regularización.

1.3.2. Objetivos específicos

1. Construir una base de precios ajustados de las empresas pertenecientes al S&P 500 y limpiarla mediante criterios explícitos de cobertura temporal, ausencia de duplicados y validez de los precios.

2. Transformar los precios ajustados de las empresas y del índice en rendimientos logarítmicos diarios y alinear ambas fuentes mediante sus fechas comunes de cotización.

3. Describir la estructura de dependencia entre los rendimientos empresariales, con énfasis en la presencia de correlaciones elevadas que justifican el uso de regularización.

4. Dividir las observaciones en conjuntos cronológicos de entrenamiento y prueba, destinando el primer 80 % a la estimación y selección del modelo y el 20 % final a su evaluación fuera de muestra.

5. Seleccionar el parámetro λ mediante validación temporal de origen móvil y aplicar la regla de un error estándar para favorecer una solución regularizada y estable.

6. Ajustar el modelo ridge definitivo con el conjunto completo de entrenamiento y examinar la magnitud y la trayectoria de sus coeficientes.

7. Evaluar el desempeño dentro y fuera de muestra mediante el error cuadrático medio, la raíz del error cuadrático medio, el error absoluto medio, el coeficiente de determinación y la correlación entre rendimientos observados y estimados.

8. Examinar los residuos del modelo para identificar autocorrelación, heterocedasticidad, desviaciones de normalidad y dependencia temporal en su magnitud.

9. Comparar el desempeño fuera de muestra de ridge con una referencia que predice la media del rendimiento del índice calculada exclusivamente en el conjunto de entrenamiento.

1.4. Hipótesis de investigación

La hipótesis principal sostiene que la penalización ridge permite aprovechar la información conjunta de empresas cuyos rendimientos están correlacionados y, al mismo tiempo, controlar la inestabilidad asociada a la estimación de un modelo con numerosos predictores. Su contrastación se realizará exclusivamente en la muestra de prueba cronológicamente posterior.

H_0: La regresión ridge no mejora la capacidad de seguimiento fuera de muestra respecto de la referencia basada en la media del conjunto de entrenamiento. En particular,

$$\mathrm{MSE}_{\text{ridge, prueba}} \geq \mathrm{MSE}_{\text{media, prueba}} .$$

H_1: La regresión ridge mejora la capacidad de seguimiento fuera de muestra respecto de la referencia basada en la media del conjunto de entrenamiento. En particular,

$$\mathrm{MSE}_{\text{ridge, prueba}} < \mathrm{MSE}_{\text{media, prueba}} .$$

Como evidencia complementaria a favor de H_1, se espera que el modelo ridge presente un R^2 fuera de muestra positivo, una correlación positiva y elevada entre los rendimientos observados y estimados, y valores de RMSE y MAE inferiores a los obtenidos por la referencia. Estas medidas no sustituyen el criterio principal basado en el MSE, pero permiten caracterizar con mayor amplitud la calidad del seguimiento. Debido a que el diseño utiliza variables contemporáneas, la hipótesis se refiere exclusivamente a capacidad explicativa y de réplica fuera de muestra; no implica predictibilidad del rendimiento futuro del índice.

Capítulo 2

Metodología

2.1. Limpieza de la base de precios

La limpieza comienza con el cálculo del número y porcentaje de valores faltantes de cada empresa. También se distingue entre valores ausentes anteriores a la primera observación disponible y vacíos internos ubicados entre la primera y la última cotización observada. Esta distinción permite separar historiales breves, asociados por ejemplo a incorporaciones recientes, de interrupciones puntuales dentro de una serie activa.

El código considera inicialmente un umbral máximo de 20 % de datos faltantes y analiza el costo de conservar empresas con un inicio tardío. Dicho costo se cuantifica mediante el producto entre la cantidad de fechas comunes y el número de empresas conservadas. A partir de esta comparación se eliminan las series que restringen de manera excesiva la cobertura temporal. El caso puntual de FISV del 12 de noviembre de 2025 se trata mediante la sustitución documentada del precio faltante por USD 64,38.

Después de la limpieza se comprueba que la matriz no contenga precios no positivos, fechas duplicadas ni símbolos repetidos. Estas validaciones son necesarias porque los precios no positivos impiden calcular logaritmos y los duplicados pueden alterar la alineación temporal. La matriz resultante constituye la base para calcular los rendimientos.

2.2. Construcción de las variables

Para cada activo j, el rendimiento logarítmico diario se define como

$$r_{j,t} = \log\left(\frac{P_{j,t}}{P_{j,t-1}}\right) = \log(P_{j,t}) - \log(P_{j,t-1}), \tag{2.1}$$

donde $P_{j,t}$ representa el precio ajustado de la empresa j en la fecha t. De manera análoga, la variable respuesta es

$$y_t = \log\left(\frac{I_t}{I_{t-1}}\right), \tag{2.2}$$

donde I_t corresponde al precio ajustado del S&P 500.

La respuesta y los predictores se combinan mediante una unión interna por fecha. En consecuencia, solo se conservan las jornadas presentes en ambas fuentes. Si alguna empresa presenta varianza nula después de la alineación, se elimina antes del ajuste, porque no aporta información y no puede estandarizarse. La matriz final de predictores se denota por $\mathbf{X} \in \mathbb{R}^{n\times p}$ y el vector de rendimientos del índice por $\mathbf{y} \in \mathbb{R}^n$.

Como diagnóstico previo se calcula la matriz de correlaciones entre los rendimientos empresariales y se contabilizan los pares cuya correlación absoluta supera los umbrales 0,70, 0,80 y 0,90. Este análisis describe la intensidad de la dependencia transversal, pero no se utiliza para eliminar predictores, ya que ridge está diseñado precisamente para estabilizar modelos con variables correlacionadas.

2.3. Especificación de la regresión ridge

Para un valor dado de $\lambda \geq 0$, el estimador ridge se define como

$$\widehat{\boldsymbol{\beta}}^R(\lambda) = \arg\min_{\boldsymbol{\beta}} \left\{ \|\mathbf{y} - \beta_0\mathbf{1} - \mathbf{X}\boldsymbol{\beta}\|_2^2 + \lambda\|\boldsymbol{\beta}\|_2^2 \right\}, \tag{2.3}$$

donde β_0 es el intercepto, $\boldsymbol{\beta}$ contiene los coeficientes de las empresas y λ controla la intensidad de la contracción. El intercepto no se penaliza.

En su formulación matricial, cuando los datos están centrados, la solución para las pendientes es

$$\widehat{\boldsymbol{\beta}}^R(\lambda) = \left(\mathbf{X}^\mathsf{T}\mathbf{X} + \lambda\mathbf{I}_p\right)^{-1}\mathbf{X}^\mathsf{T}\mathbf{y}. \tag{2.4}$$

La suma de $\lambda\mathbf{I}_p$ incrementa los valores propios de la matriz normal y permite obtener una solución estable aun cuando existan dependencias fuertes entre las columnas de $\mathbf{X}$.

El modelo se estima en R[8] mediante el paquete `glmnet`[4], utilizando `family = "gaussian"` y `alpha = 0`, configuración que corresponde exclusivamente a ridge. Se mantiene el intercepto y se activa la estandarización interna. En cada ajuste, las medias y desviaciones se calculan solamente con el bloque de entrenamiento entregado al algoritmo; las mismas transformaciones se aplican posteriormente al bloque de validación o prueba. De este modo se evita utilizar información futura durante el preprocesamiento.

2.4. Partición cronológica y validación temporal

Las observaciones se mantienen en orden ascendente por fecha. El primer 80 % se asigna al conjunto de entrenamiento y el 20 % final se reserva como muestra de prueba. Formalmente, si $n_{\text{train}} = \lfloor 0{,}8n \rfloor$, entonces

$$\mathcal{D}_{\text{train}} = \{1, \ldots, n_{\text{train}}\}, \qquad \mathcal{D}_{\text{test}} = \{n_{\text{train}} + 1, \ldots, n\}. \tag{2.5}$$

La selección de λ se realiza exclusivamente dentro de $\mathcal{D}_{\text{train}}$. La primera mitad de este conjunto forma la ventana histórica inicial y la segunda mitad se divide en cinco bloques consecutivos. En la iteración k, el modelo se estima con todas las observaciones anteriores al bloque k y se evalúa en dicho bloque. La ventana de estimación, por tanto, se expande a medida que avanza el origen temporal.

Para cada valor candidato de λ, el criterio de validación es

$$\widehat{R}_{\text{CV}}(\lambda) = \frac{1}{K} \sum_{k=1}^{K} \frac{1}{n_k} \sum_{t \in \mathcal{V}_k} \left(y_t - \widehat{y}_t^{(-k)}(\lambda) \right)^2, \qquad K = 5, \tag{2.6}$$

donde $\mathcal{V}_k$ es el bloque de validación, n_k su número de observaciones y $\widehat{y}_t^{(-k)}(\lambda)$ la estimación obtenida sin utilizar ese bloque ni observaciones posteriores.

Se evalúan 200 valores de λ distribuidos logarítmicamente entre 10^{-8} y 1. Primero se identifica

$$\lambda_{\text{mín}} = \arg\min_{\lambda} \widehat{R}_{\text{CV}}(\lambda). \tag{2.7}$$

Luego se aplica la regla de un error estándar y se selecciona el mayor valor que satisface

$$\widehat{R}_{\text{CV}}(\lambda) \leq \widehat{R}_{\text{CV}}(\lambda_{\text{mín}}) + \widehat{\text{se}}\left\{ \widehat{R}_{\text{CV}}(\lambda_{\text{mín}}) \right\}. \tag{2.8}$$

Este valor se denota por $\lambda_{1\mathrm{SE}}$ y constituye el hiperparámetro definitivo, porque favorece una mayor regularización dentro de un margen de desempeño compatible con el mínimo estimado.

2.5. Ajuste final y evaluación fuera de muestra

Una vez seleccionado $\lambda_{1\mathrm{SE}}$, el modelo se vuelve a estimar utilizando todas las observaciones del conjunto de entrenamiento. La muestra de prueba no interviene en la selección del hiperparámetro ni en la estimación del modelo final. Sobre ella se calculan las predicciones $\widehat{y}_t$ y los residuos $e_t = y_t - \widehat{y}_t$.

El desempeño se resume mediante las siguientes medidas:

$$\mathrm{MSE} = \frac{1}{m}\sum_{t=1}^{m}(y_t - \widehat{y}_t)^2, \tag{2.9}$$

$$\mathrm{RMSE} = \sqrt{\mathrm{MSE}}, \tag{2.10}$$

$$\mathrm{MAE} = \frac{1}{m}\sum_{t=1}^{m}|y_t - \widehat{y}_t|, \tag{2.11}$$

$$R^2 = 1 - \frac{\sum_{t=1}^{m}(y_t - \widehat{y}_t)^2}{\sum_{t=1}^{m}(y_t - \overline{y})^2}. \tag{2.12}$$

También se calcula la correlación de Pearson entre los rendimientos observados y estimados. Las métricas se presentan tanto para entrenamiento como para prueba, aunque la evaluación principal corresponde a esta última.

Como referencia se emplea un modelo ingenuo que asigna a todas las observaciones de prueba la media del rendimiento del índice calculada en el entrenamiento:

$$\widehat{y}_t^{\,\mathrm{media}} = \overline{y}_{\mathrm{train}}. \tag{2.13}$$

La hipótesis principal se considera respaldada si el MSE de ridge en la muestra de prueba es menor que el MSE de esta referencia. El análisis se complementa con la comparación del RMSE, MAE, R^2 y correlación.

2.6. Diagnóstico de residuos

La evaluación predictiva se complementa con un diagnóstico de los residuos $e_t = y_t - \widehat{y}_t$, efectuado por separado en entrenamiento y prueba. Este análisis no interviene en la selección de λ y, por tanto, no modifica la condición de evaluación final de la muestra de prueba.

La dependencia lineal temporal se examina mediante la prueba de Ljung–Box con 20 rezagos. La misma prueba aplicada a e_t^2 se utiliza como diagnóstico de dependencia en la magnitud de los errores y de posible agrupamiento de volatilidad. La relación entre la varianza residual y el nivel de la predicción se evalúa mediante una regresión auxiliar de e_t^2 sobre $\widehat{y}_t$ y $\widehat{y}_t^2$, cuyo estadístico es nR^2 y se compara con una distribución χ^2 con dos grados de libertad.

Asimismo, se construyen gráficos de residuos frente a valores ajustados, funciones de autocorrelación para e_t y e_t^2, y gráficos cuantil–cuantil. La prueba de Jarque–Bera se incorpora únicamente para describir la forma de la distribución residual. La normalidad no se considera una condición necesaria para calcular el estimador ridge ni para obtener predicciones, aunque su incumplimiento limita el uso de inferencia paramétrica convencional.

Capítulo 3

Datos

3.1. Fuentes de información y período de estudio

Los nombres, símbolos bursátiles y sectores económicos de las empresas que componen el S&P 500 se obtuvieron desde TradingView[11]. Los símbolos se adaptaron al formato de Yahoo Finance, sustituyendo los puntos por guiones cuando correspondía. La nómina completa de empresas se presenta en el Apéndice A, mientras que su distribución por sector económico se resume en la Tabla B.1 del Apéndice B.

Los precios ajustados diarios de las acciones y del índice se descargaron desde Yahoo Finance mediante el paquete `quantmod` de R[9]. El período solicitado se extendió desde el 1 de enero de 2021 hasta el 21 de septiembre de 2026. Debido a que el argumento final de la función `getSymbols` es excluyente, se agregó un día a la fecha de término para intentar incorporar la última jornada definida. El período efectivo quedó determinado por la intersección de las fechas disponibles para el índice y las empresas conservadas.

Se utilizaron precios ajustados porque incorporan los eventos corporativos registrados por la fuente, como divisiones de acciones y distribuciones. La composición consultada corresponde al momento de ejecutar el código y no reconstruye la pertenencia histórica al índice; esta limitación se desarrolla en el Capítulo 5. Antes del análisis se aplicó un proceso de limpieza orientado a obtener series comparables, alineadas y con cobertura suficiente.

El código empleado para la descarga y depuración de los datos, la estimación del modelo y la generación de los resultados se encuentra disponible en el repositorio público del proyecto[12].

3.2. Limpieza y tratamiento

La base original contiene una matriz de precios compuesta por 1 435 fechas de cotización y 503 empresas. Para cada empresa se calculó el número total de observaciones faltantes y su porcentaje respecto del total de fechas:

$$p_j^{\mathrm{NA}} = 100\frac{\sum_{t=1}^{T}\mathbb{I}(P_{j,t}\text{ es NA})}{T}, \tag{3.1}$$

donde $P_{j,t}$ es el precio ajustado de la empresa j en la fecha t y T es el número total de jornadas de la matriz original.

De las 503 empresas analizadas, 16 presentaron al menos una observación faltante. Las mayores proporciones correspondieron a HONA, FDXF, Q y SNDK, cuyas series contenían más de un 70 % de datos faltantes. Como análisis exploratorio se aplicó el límite superior del rango intercuartílico,

$$L_s = Q_3 + 1{,}5(Q_3 - Q_1). \tag{3.2}$$

Debido a que la mayoría de las empresas no presentaba datos faltantes, $Q_1 = Q_3 = 0$ y, en consecuencia, $L_s = 0$. Por esta razón, todas las empresas con al menos un valor ausente fueron identificadas como casos atípicos y examinadas individualmente.

3.2.1. Patrón de los datos faltantes

Los valores faltantes podían responder a dos situaciones diferentes: observaciones anteriores al inicio efectivo de cotización de una empresa o interrupciones dentro de una serie ya activa. La distinción es relevante porque una observación anterior a la primera cotización no constituye un dato perdido y no debe imputarse como si fuese una ausencia aleatoria.

Para cada empresa se identificaron la primera y la última observación disponibles. El porcentaje de ausencias internas se calculó mediante

$$p_{j,\mathrm{int}}^{\mathrm{NA}} = 100\frac{N_{j,\mathrm{int}}^{\mathrm{NA}}}{T_{j,\mathrm{efectivo}}}, \tag{3.3}$$

donde $N_{j,\mathrm{int}}^{\mathrm{NA}}$ es el número de ausencias comprendidas entre la primera y la última cotización observada y $T_{j,\mathrm{efectivo}}$ es la longitud de ese intervalo.

El análisis mostró que, con excepción de FISV, los valores faltantes se concentraban antes de la primera observación disponible. En consecuencia, estos casos se relacionaban

principalmente con empresas que comenzaron a cotizar después del inicio del estudio. FISV presentó una única ausencia interna, correspondiente al 12 de noviembre de 2025.

3.2.2. Cobertura individual y conjunta

Inicialmente se estableció como requisito que cada empresa contara con al menos un 80 % de cobertura temporal:

$$\text{conservar } j \quad \Longleftrightarrow \quad p_j^{\mathrm{NA}} \leq 20\,\%. \tag{3.4}$$

Este criterio identificó diez empresas con cobertura insuficiente: HONA, FDXF, Q, SNDK, GEV, SOLV, RDDT, VLTO, KVUE y GEHC. Sus porcentajes de ausencia se situaron entre 34,29 % y 95,26 % y se concentraron antes del inicio de sus series.

CEG, HOOD, APP, COIN y EXE presentaron porcentajes inferiores al 20 %; sin embargo, su conservación podía desplazar la fecha inicial común y eliminar observaciones válidas de todas las demás empresas. Para evaluar este costo se definió, para cada escenario s, la cantidad potencial de información

$$\mathcal{I}_s = N_{s,\text{fechas}} N_{s,\text{empresas}}. \tag{3.5}$$

Cuadro 3.1: Evaluación de los escenarios de cobertura temporal

Escenario	**Empresas**	**Fecha inicial**	**Fechas**	**Información**
Conservar todas	492	19-01-2022	1 172	576 624
Eliminar CEG	491	29-07-2021	1 292	634 372
Eliminar CEG y HOOD	490	15-04-2021	1 365	668 850
Eliminar CEG, HOOD y APP	489	14-04-2021	1 366	667 974
Eliminar CEG, HOOD, APP y COIN	488	10-02-2021	1 409	687 592
Eliminar CEG, HOOD, APP, COIN y EXE	487	04-01-2021	1 435	698 845

La eliminación de CEG permitió recuperar 120 fechas e incrementar la información disponible en un 10,01 %. La exclusión adicional de HOOD recuperó otras 73 fechas y produjo un aumento adicional de 5,43 %. Eliminar únicamente APP no resultó conveniente, pues recuperó una sola fecha y redujo la información total en 0,13 %. No obstante, la exclusión conjunta de CEG, HOOD, APP, COIN y EXE produjo el mayor volumen potencial de información, con 698 845 observaciones y una ganancia de 21,20 % respecto del escenario que conservaba todas las series parciales.

En consecuencia, se excluyeron quince empresas con cobertura temporal parcial: HONA, FDXF, Q, SNDK, GEV, SOLV, RDDT, VLTO, KVUE, GEHC, CEG, HOOD, APP, COIN y EXE. Esta decisión permitió conservar el período completo para las empresas restantes.

3.2.3. Tratamiento del valor faltante de FISV

FISV se trató separadamente porque presentaba una única ausencia dentro de su período efectivo de cotización. Después de contrastar el registro con Yahoo Finance[13], se verificó que la acción había cotizado el 12 de noviembre de 2025 y que su precio de cierre era USD 64,38. El dato se restituyó utilizando ese valor. La corrección no corresponde a una interpolación ni a una estimación estadística, sino a la recuperación del precio registrado por la fuente financiera.

3.2.4. Base de Datos Limpia

La matriz limpiada quedó conformada por 1 435 fechas y 488 empresas. Se comprobó que no existieran valores faltantes, precios no positivos, fechas duplicadas ni símbolos repetidos. A partir de los precios se obtuvieron 1 434 rendimientos logarítmicos diarios por empresa, correspondientes al período comprendido entre el 4 de enero de 2021 y el 21 de septiembre de 2026.

3.3. Análisis descriptivo

El análisis se concentra principalmente en los rendimientos, debido a que los precios se expresan en escalas nominales diferentes y sus medias o desviaciones estándar no son directamente comparables. Los rendimientos logarítmicos permiten examinar de manera homogénea la evolución y variabilidad de las empresas.

3.3.1. Distribución transversal de los rendimientos

La Tabla 3.2 resume los principales indicadores de las 488 empresas.

El rendimiento anualizado promedio fue de 10,70 % y la mediana alcanzó 9,54 %. Sin embargo, los valores variaron entre −29,13 % y 61,15 %, lo que evidencia una heterogeneidad considerable. La volatilidad anualizada promedio fue de 32,08 %, con una mediana de 29,53 % y un máximo de 104,37 %.

Cuadro 3.2: Resumen descriptivo de los indicadores por empresa

Estadístico	**Rendimiento anualizado**	**Volatilidad anualizada**	**Rendimiento acumulado**
Media	10,70 %	32,08 %	149,15 %
Mediana	9,54 %	29,53 %	72,13 %
Desviación estándar	12,90 %	10,82 %	271,85 %
Mínimo	-29,13 %	16,38 %	-80,94 %
Primer cuartil	2,91 %	24,61 %	18,00 %
Tercer cuartil	17,58 %	36,68 %	171,89 %
Máximo	61,15 %	104,37 %	3 144,94 %

El rendimiento acumulado promedio fue de 149,15 %, frente a una mediana de 72,13 %. La diferencia responde a un conjunto reducido de empresas con crecimientos extraordinarios que eleva la media; la desviación estándar de 271,85 % confirma la elevada dispersión entre las trayectorias individuales.

3.3.2. Indicador equiponderado

Como representación descriptiva conjunta se calculó el promedio transversal de los rendimientos diarios,

$$r_t^{\mathrm{EW}} = \frac{1}{p}\sum_{j=1}^{p} r_{j,t}, \qquad V_t = 100\exp\left(\sum_{s=1}^{t} r_s^{\mathrm{EW}}\right). \tag{3.6}$$

Este indicador no reproduce exactamente el S&P 500 oficial, cuyo esquema utiliza la capitalización bursátil ajustada por flotación.

El indicador aumentó desde una base de 100 hasta aproximadamente 184 puntos, equivalente a un crecimiento acumulado de 83,86 %. Su rendimiento logarítmico diario promedio fue de 0,0425 % y la volatilidad anualizada alcanzó 16,24 %, valor considerablemente inferior al promedio individual de 32,08 %. Esta diferencia refleja el efecto de diversificación generado por la compensación parcial de fluctuaciones específicas.

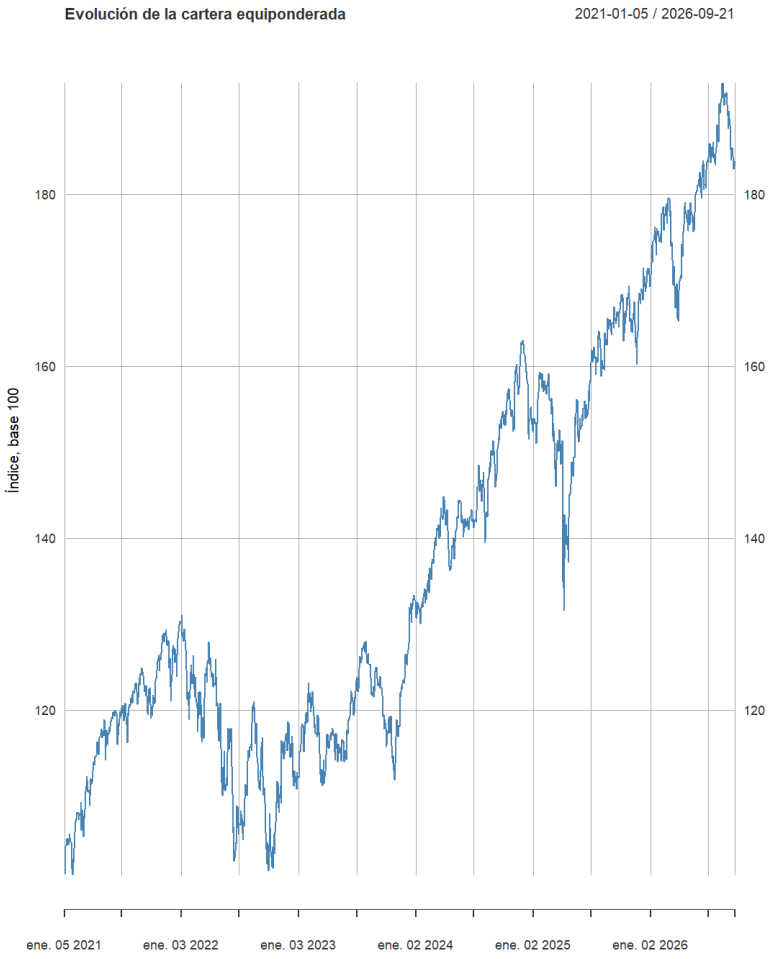


Figura 3.1: Evolución del indicador equiponderado, base 100

3.3.3. Evolución anual

Cuadro 3.3: Comportamiento anual del indicador equiponderado

Año	Rendimiento acumulado	Volatilidad anualizada	Mínimo diario	Días positivos
2021	30,18 %	13,55 %	-2,59 %	57,77 %
2022	-13,68 %	23,82 %	-4,25 %	47,01 %
2023	18,28 %	14,24 %	-2,17 %	52,40 %
2024	14,92 %	11,85 %	-3,02 %	55,16 %
2025	10,81 %	17,86 %	-6,00 %	50,40 %
2026	8,63 %	11,65 %	-1,71 %	53,89 %

El año 2021 registró el mayor rendimiento acumulado, con 30,18 %. En contraste, 2022 fue el único año negativo, con $-13{,}68\,\%$, y también presentó la mayor volatilidad anualizada, de 23,82 %. Durante 2023 y 2024 se observó una recuperación, con rendimientos de 18,28 % y 14,92 %. El resultado de 2026 debe interpretarse con cautela, pues comprende solamente el período transcurrido hasta el 21 de septiembre.

La distribución anual de los rendimientos se presenta como material gráfico complementario en la Figura C.1 del apéndice.

3.3.4. Distribución y jornadas atípicas

La media diaria del indicador fue de 0,0425 %, su mediana de 0,0576 % y su desviación estándar de 1,02 %. El coeficiente de asimetría fue $-0{,}049$, cercano a cero, mientras que el exceso de curtosis alcanzó 5,23. En consecuencia, la distribución es aproximadamente simétrica, pero leptocúrtica y con colas más pesadas que una distribución normal.

El histograma y el gráfico Q–Q que respaldan esta descripción se presentan en la Figura C.2 del apéndice.

Mediante el criterio del rango intercuartílico se identificaron 44 jornadas atípicas, concentradas principalmente en 2022 y abril de 2025. La mayor caída fue de $-6{,}00\,\%$ el 4 de abril de 2025, mientras que el mayor incremento alcanzó 8,10 % el 9 de abril del mismo año. La proximidad temporal de varios movimientos extremos sugiere agrupamiento de volatilidad.

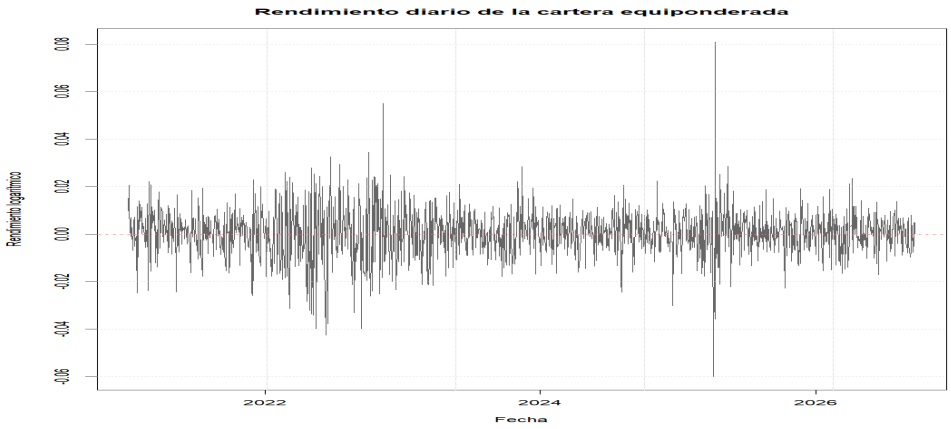


Figura 3.2: Rendimientos diarios del indicador equiponderado

3.3.5. Rendimiento, volatilidad y riesgo empresarial

FIX obtuvo el mayor rendimiento acumulado, equivalente a 3 144,94 %, seguida por NVDA, DELL y STX, cuyos rendimientos superaron 1 600 %. Varias de las acciones de mejor desempeño también presentaron volatilidades o caídas máximas elevadas. Por ejemplo, SMCI acumuló 1 226,89 %, pero registró una volatilidad anualizada de 83,77 % y una caída máxima de 84,84 %.

En el extremo opuesto, CHTR presentó el peor rendimiento acumulado, con −80,94 %, seguida de PYPL, ALGN, NKE y LULU. Respecto de la volatilidad, CVNA alcanzó el máximo de 104,37 % y una caída máxima de 98,99 %. KO presentó la menor volatilidad anualizada, con 16,38 %. Estos resultados confirman que el rendimiento final no resume por sí solo el riesgo experimentado durante la trayectoria.

La relación entre volatilidad y rendimiento anualizado fue positiva, pero débil y considerablemente dispersa. Para niveles semejantes de volatilidad se observaron resultados muy diferentes, por lo que asumir un mayor riesgo no garantizó un rendimiento superior.

3.3.6. Estructura de correlaciones

La correlación promedio entre los rendimientos empresariales fue de 0,2589 y la mediana alcanzó 0,2515. La mitad central de las correlaciones se ubicó entre 0,1690 y 0,3404, lo que indica dependencia positiva moderada y, simultáneamente, margen para diversificación.

La correlación máxima, de 0,9953, correspondió a GOOGL y GOOG, dos clases de acciones de la misma compañía. También se observaron relaciones elevadas entre FOXA y FOX (0,9868), NWSA y NWS (0,9731), AMAT y LRCX (0,9168), MLM y VMC (0,9139),

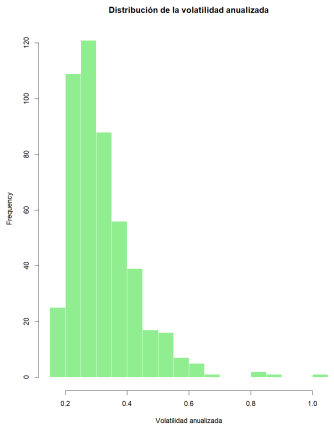


Figura 3.3: Distribución de la volatilidad anualizada

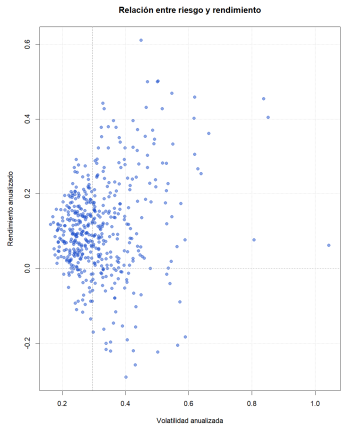


Figura 3.4: Relación entre volatilidad y rendimiento anualizado

DHI y LEN (0,9107), y CPT y MAA (0,9101). La correlación mínima fue de $-0{,}2060$, entre COHR y GIS.

La coexistencia de numerosos pares altamente correlacionados y un número elevado de predictores justifica el uso posterior de regresión ridge. La penalización cuadrática permite estabilizar el ajuste sin eliminar automáticamente empresas y resulta especialmente pertinente cuando la información común se distribuye entre grupos de acciones relacionadas.

Capítulo 4

Resultados

4.1. Muestra utilizada en la estimación

Después de alinear temporalmente los rendimientos de las empresas con el rendimiento del S&P 500, la base utilizada por el modelo quedó conformada por 1 434 observaciones diarias y 487 variables explicativas. El período común se extiende desde el 5 de enero de 2021 hasta el 21 de septiembre de 2026. La diferencia respecto de las 488 empresas de la matriz de precios limpiada se debe a la exclusión automática de una variable que no cumplía las condiciones necesarias para ingresar como predictor después de la transformación y alineación.

La división cronológica asignó 1 147 observaciones al entrenamiento, equivalentes al primer 80 % de la muestra, y 287 observaciones a la prueba final. La Tabla 4.1 presenta los períodos efectivos.

Cuadro 4.1: Partición cronológica de la muestra

Muestra	**Fecha inicial**	**Fecha final**	**Observaciones**
Entrenamiento	05-01-2021	30-07-2025	1 147
Prueba	31-07-2025	21-09-2026	287

El diagnóstico de multicolinealidad confirmó la presencia de dependencia elevada entre una parte de los predictores. Se identificaron 470 pares con correlación absoluta superior a 0,70, 140 pares por encima de 0,80 y 11 pares con correlación absoluta mayor que 0,90. Estos resultados respaldan el uso de ridge, pues una estimación sin penalización puede ser sensible a la información redundante compartida por las acciones.

Cuadro 4.2: Número de pares con correlación absoluta elevada

Umbral	Número de pares
$\lvert r\rvert > 0{,}70$	470
$\lvert r\rvert > 0{,}80$	140
$\lvert r\rvert > 0{,}90$	11

4.2. Presentación gráfica de los resultados

Los resultados se complementan con cuatro representaciones principales. La curva del MSE de validación frente a $\log_{10}(\lambda)$ muestra la ubicación de $\lambda_{\text{mín}}$ y λ_{1SE}. La serie temporal de rendimientos observados y estimados, junto con el gráfico de dispersión frente a la recta de 45°, permite evaluar la concordancia fuera de muestra. Finalmente, el gráfico de los coeficientes de mayor magnitud resume la contribución lineal de las empresas más destacadas.

Los coeficientes se ordenan por su magnitud absoluta con fines descriptivos. Esta ordenación no se interpreta como selección de variables ni como evidencia causal, puesto que ridge generalmente conserva coeficientes distintos de cero y la correlación entre activos dificulta atribuir efectos aislados.

4.3. Selección del parámetro de regularización

La validación temporal se aplicó sobre una grilla de 200 valores de λ. El menor error cuadrático medio de validación se obtuvo con $\lambda_{\text{mín}} = 0{,}0001825183$.

La regla de un error estándar seleccionó $\lambda_{\text{1SE}} = 0{,}0016831804$, valor aproximadamente 9,22 veces mayor que $\lambda_{\text{mín}}$. Esta diferencia indica que fue posible aumentar de manera considerable la intensidad de la penalización sin exceder el margen de un error estándar respecto del mínimo estimado. Conforme al procedimiento definido previamente, λ_{1SE} se adoptó como parámetro final.

La elección favorece un modelo más contraído y potencialmente más estable que el obtenido mediante la regla del mínimo. No obstante, la validez de esta decisión debe juzgarse a partir de la muestra de prueba, la cual no participó en la selección de ninguno de los dos valores.

La Figura 4.1 permite visualizar el comportamiento del error de validación a lo largo de la grilla y la ubicación de los dos valores candidatos. La distancia entre ambas líneas verticales muestra gráficamente el aumento de regularización introducido por la regla de

un error estándar.

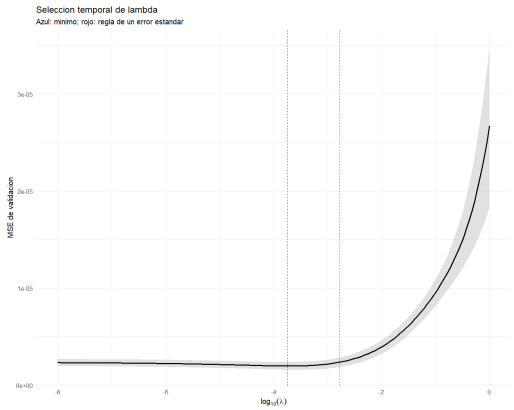


Figura 4.1: Error cuadrático medio de validación temporal según el valor de λ

Cuadro 4.3: Valores seleccionados del parámetro ridge

Regla	**Valor de λ**
Mínimo de validación	0,0001825183
Un error estándar	0,0016831804
Selección final	0,0016831804

4.4. Desempeño dentro y fuera de muestra

La Tabla 4.4 compara el ajuste ridge en entrenamiento y prueba con la referencia que predice constantemente la media del entrenamiento. En la muestra de entrenamiento, ridge obtuvo un MSE de $5{,}0859 \times 10^{-7}$ y un R^2 de 0,9957. Estos valores muestran que la combinación regularizada reproduce casi completamente la variación contemporánea del índice dentro del período utilizado para estimar los coeficientes.

Cuadro 4.4: Métricas de desempeño del modelo ridge

Muestra	**MSE**	**RMSE**	**MAE**	R^2	**Correlación**
Entrenamiento ridge	$5{,}0859 \times 10^{-7}$	0,0007132	0,0005405	0,9957	0,9979
Prueba ridge	$7{,}7127 \times 10^{-6}$	0,0027772	0,0020622	0,8781	0,9396
Prueba media	$6{,}3332 \times 10^{-5}$	0,0079581	0,0060726	−0,0008	—

Como era esperable, el desempeño disminuyó en la muestra de prueba: el MSE aumentó a $7{,}7127 \times 10^{-6}$ y el R^2 descendió a 0,8781. La diferencia entre entrenamiento y prueba

revela que el ajuste dentro de muestra sobreestima la capacidad de réplica que puede esperarse en observaciones nuevas. Sin embargo, el nivel alcanzado fuera de muestra continúa siendo elevado: la correlación entre el rendimiento observado y el estimado fue de 0,9396.

La referencia basada en la media presentó un MSE de $6{,}3332 \times 10^{-5}$, un RMSE de 0,0079581 y un MAE de 0,0060726. Frente a ella, ridge redujo el MSE en aproximadamente 87,82 %, el RMSE en 65,10 % y el MAE en 66,04 %. El R^2 negativo de la referencia indica que predecir la media del entrenamiento fue ligeramente peor que utilizar la media de la propia muestra de prueba como referencia retrospectiva.

La Figura 4.2 compara cronológicamente los rendimientos observados y estimados durante la muestra de prueba. Por su parte, la Figura 4.3 representa la proximidad de cada predicción a la recta de concordancia de 45°. En conjunto, ambas figuras permiten examinar si el desempeño agregado informado en la Tabla 4.4 se mantiene a lo largo del período y frente a observaciones de distinta magnitud.

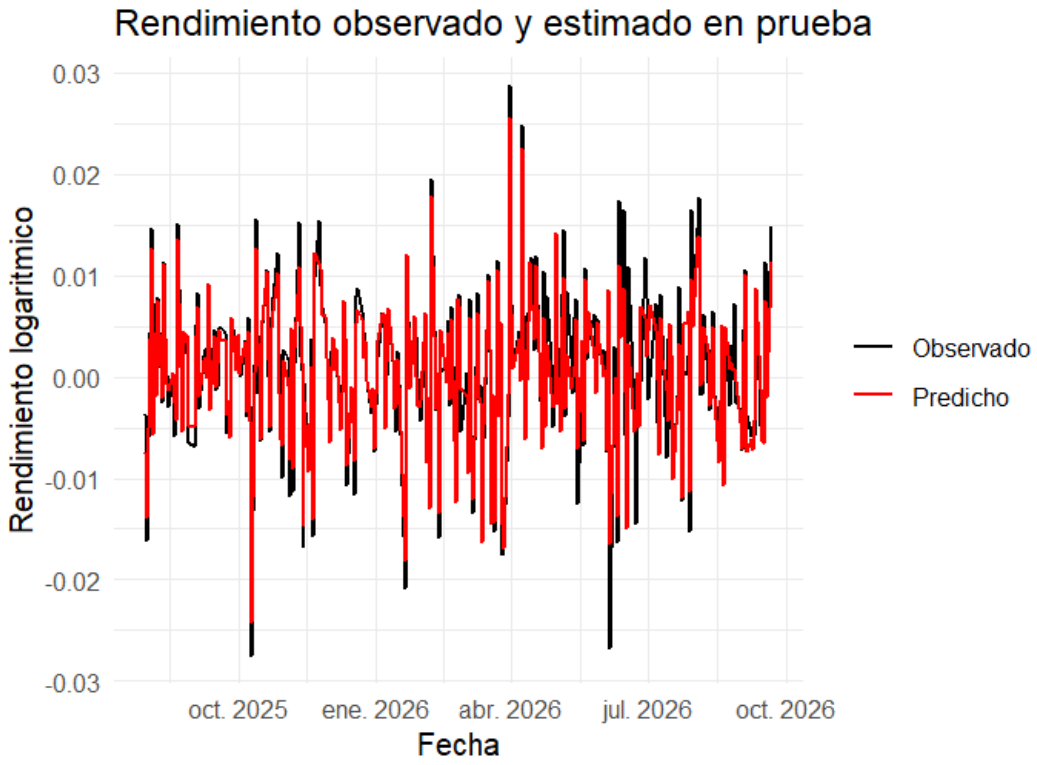


Figura 4.2: Rendimientos observados y estimados por ridge en la muestra de prueba

Estos resultados respaldan la hipótesis de investigación planteada: el MSE de ridge en prueba fue estrictamente menor que el MSE del modelo basado en la media,

$$7{,}7127 \times 10^{-6} < 6{,}3332 \times 10^{-5}.$$

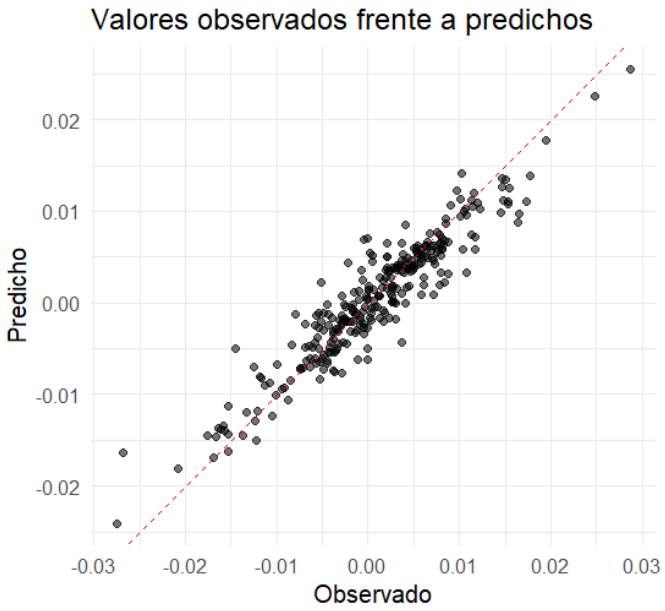


Figura 4.3: Rendimientos observados frente a estimados en la muestra de prueba

Por tanto, la comparación descriptiva favorece H_1 frente a H_0. Esta evidencia se refiere a la capacidad de seguimiento contemporáneo durante la muestra analizada; no constituye una prueba formal de significancia ni demuestra predictibilidad de rendimientos futuros.

4.5. Diagnóstico de residuos

La Tabla 4.5 resume los diagnósticos obtenidos. En entrenamiento, la prueba de Ljung–Box aplicada a los residuos no rechazó la ausencia de autocorrelación conjunta hasta el rezago 20 ($Q = 24{,}6641$, $p = 0{,}2146$). En prueba, el resultado fue más ajustado y llevó al rechazo al nivel de 5 % ($Q = 32{,}5896$, $p = 0{,}0374$), lo que indica dependencia lineal residual leve durante el período fuera de muestra.

Cuadro 4.5: Diagnósticos de los residuos del modelo ridge

Muestra	p **LB**(e_t)	p **LB**(e_t^2)	p **heteroc.**	p **JB**
Entrenamiento	0,2146	$< 10^{-16}$	0,0051	$< 10^{-20}$
Prueba	0,0374	$< 10^{-16}$	0,5114	$< 0{,}0001$

LB: prueba de Ljung–Box con 20 rezagos; heteroc.: prueba auxiliar nR^2; JB: prueba de Jarque–Bera.

El resultado más marcado apareció en los residuos al cuadrado. Los estadísticos de Ljung–Box fueron 186,6073 en entrenamiento y 381,4085 en prueba, con valores p numéricamente inferiores a 10^{-16}. Por tanto, aunque la autocorrelación lineal de los errores fue limitada, su magnitud presentó dependencia temporal persistente. Este patrón es compatible con agrupamiento de volatilidad, una característica habitual de los rendimientos financieros.

La prueba auxiliar de heterocedasticidad respecto del nivel ajustado fue significativa en entrenamiento ($nR^2 = 10{,}5711$, $p = 0{,}0051$), pero no en prueba ($nR^2 = 1{,}3412$, $p = 0{,}5114$). Estos resultados no son contradictorios con la dependencia de e_t^2: la prueba auxiliar busca cambios de varianza relacionados con el valor predicho, mientras que Ljung–Box sobre los cuadrados examina persistencia temporal de la magnitud residual.

La Figura 4.4 muestra residuos concentrados alrededor de cero, pero con mayor dispersión y cierta curvatura en los extremos, especialmente en prueba. La curva suavizada debe interpretarse con cautela porque existen pocas observaciones con valores ajustados extremos.

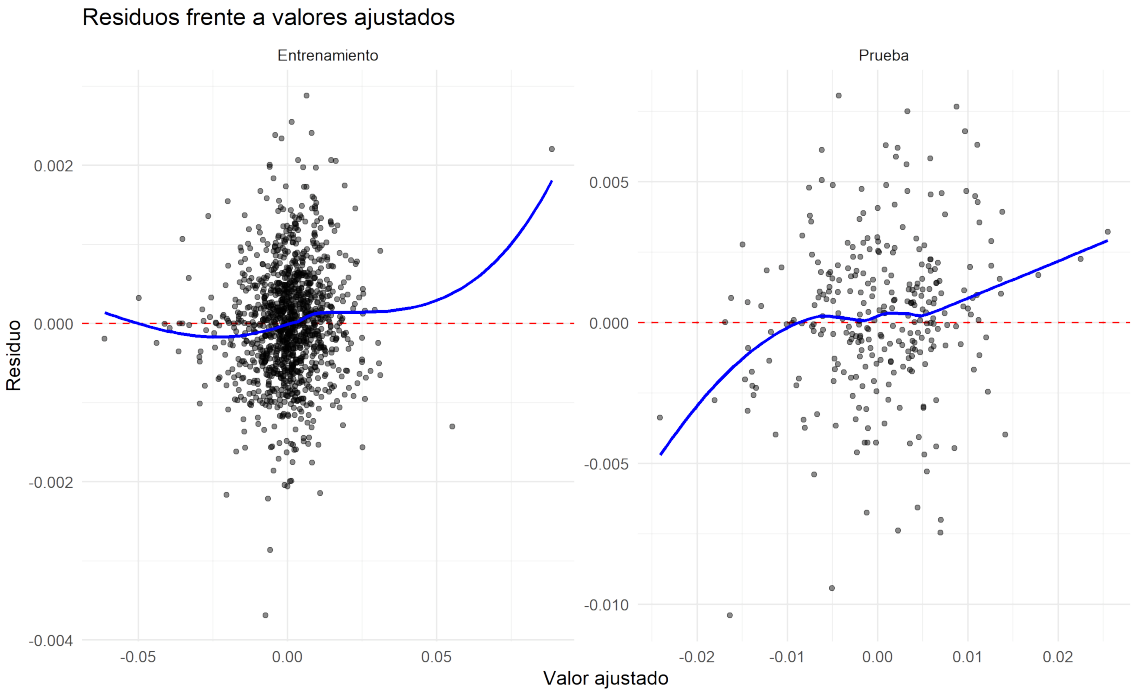


Figura 4.4: Residuos frente a valores ajustados en entrenamiento y prueba

Los gráficos cuantil–cuantil de la Figura 4.5 presentan desviaciones claras en ambas colas. Esta evidencia coincide con el rechazo de normalidad de Jarque–Bera tanto en entrenamiento ($JB = 93{,}9105$, $p < 10^{-20}$) como en prueba ($JB = 22{,}6496$, $p < 0{,}0001$).

Las curtosis observadas, iguales a 4,3977 y 4,2595, respectivamente, confirman colas más pesadas que las de una distribución normal.

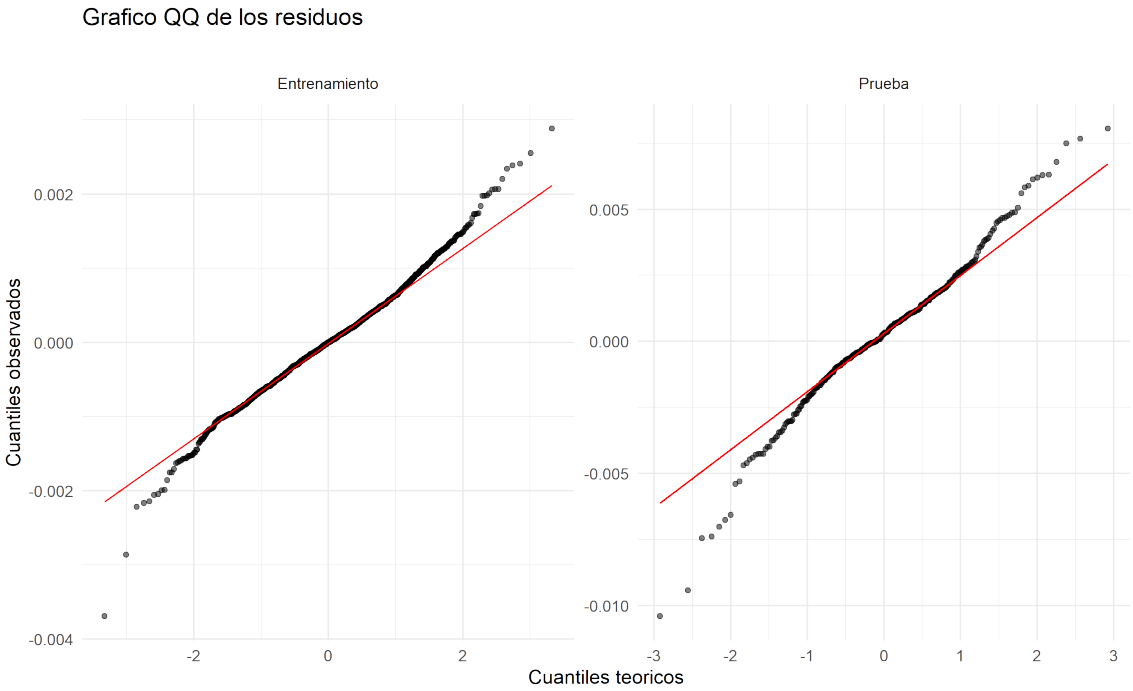


Figura 4.5: Gráficos cuantil–cuantil de los residuos ridge

La Figura C.3, incluida en el apéndice, permite distinguir visualmente ambos fenómenos. La autocorrelación de los residuos oscila en general alrededor de cero, mientras que la de sus cuadrados permanece positiva durante numerosos rezagos, sobre todo en la muestra de prueba.

En conjunto, los diagnósticos no invalidan el resultado predictivo del modelo ridge, pero muestran que una representación lineal de la media condicional no describe completamente la dinámica de la varianza. Por ello, las métricas fuera de muestra continúan siendo el criterio principal de evaluación, mientras que cualquier inferencia formal debería emplear procedimientos robustos frente a dependencia temporal, heterocedasticidad y colas pesadas.

4.6. Coeficientes del modelo ridge

La Tabla 4.6 presenta las veinte variables con coeficientes de mayor magnitud absoluta. Todos los coeficientes incluidos en este grupo fueron positivos. AAPL y MSFT registraron los valores más altos, seguidas por AMZN, GOOGL, GOOG y NVDA.

Cuadro 4.6: Veinte coeficientes ridge de mayor magnitud absoluta

Empresa	**Coef.**	**|Coef.|**	**Empresa**	**Coef.**	**|Coef.|**
AAPL	0,050843	0,050843	COST	0,013151	0,013151
MSFT	0,048140	0,048140	V	0,012263	0,012263
AMZN	0,027223	0,027223	MCD	0,012161	0,012161
GOOGL	0,021585	0,021585	LLY	0,011359	0,011359
GOOG	0,020928	0,020928	KO	0,010433	0,010433
NVDA	0,020278	0,020278	JPM	0,010342	0,010342
AVGO	0,016556	0,016556	APH	0,010120	0,010120
META	0,015008	0,015008	ORCL	0,009758	0,009758
BRK.B	0,014487	0,014487	HD	0,009229	0,009229
TSLA	0,014382	0,014382	WMT	0,009217	0,009217

La importancia relativa de AAPL y MSFT es coherente con su elevada participación económica dentro del mercado estadounidense. Asimismo, la aparición de las dos clases de acciones de Alphabet entre los principales coeficientes ilustra el comportamiento de ridge ante predictores casi redundantes: en vez de seleccionar una única variable, la penalización distribuye el efecto entre ambas.

Los coeficientes no deben interpretarse como efectos causales ni como ponderaciones oficiales del índice. Su magnitud depende de la estandarización interna, la estructura de correlación y el valor seleccionado de λ. Además, ridge no impone que las ponderaciones sumen uno ni exige posiciones no negativas, aunque los veinte coeficientes principales obtenidos en este ajuste sí presentaron signo positivo.

La Figura 4.6 complementa la tabla mediante una comparación gráfica de la magnitud de los veinte coeficientes principales. Esta representación facilita identificar la concentración relativa de los valores más altos y la contracción aplicada al resto de los predictores destacados.

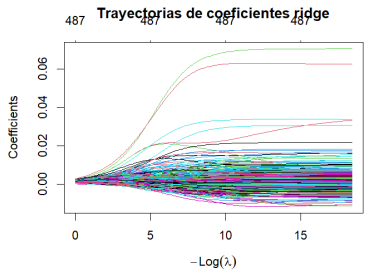


Figura 4.6: Veinte coeficientes ridge de mayor magnitud absoluta

Capítulo 5

Limitaciones

Estas limitaciones delimitan el alcance de los resultados y señalan posibles extensiones del diseño empírico.

5.1. Composición histórica y calidad de los datos

La lista de empresas corresponde a los componentes disponibles en TradingView al momento de la extracción y no reconstruye la composición exacta del S&P 500 entre 2021 y 2026. La ausencia de empresas que abandonaron el índice y la inclusión retrospectiva de incorporaciones recientes pueden generar sesgo de supervivencia y de selección. Por ello, los resultados no equivalen a los de una estrategia basada en la composición históricamente vigente.

Los precios provienen de fuentes públicas y dependen de la continuidad y los ajustes de los proveedores. Excluir quince series parciales mejoró la comparabilidad temporal, pero redujo la cobertura transversal; un panel no balanceado, otra ventana u otro tratamiento de los datos faltantes podrían producir resultados diferentes. La corrección de FISV muestra, además, que ciertas omisiones requieren verificación manual.

5.2. Alcance y construcción del índice

La respuesta y los predictores corresponden a la misma jornada. El modelo mide asociación contemporánea y seguimiento, pero no demuestra capacidad para anticipar rendimientos ni identifica una oportunidad de arbitraje. Un estudio de pronóstico requeriría predictores rezagados y considerar costos de transacción.

Ridge tampoco reproduce la metodología oficial del S&P 500: no utiliza ponderaciones por capitalización ajustada por flotación ni exige coeficientes no negativos que sumen uno. Estos no representan ponderaciones oficiales, efectos causales o una cartera inmediatamente ejecutable, pues dependen de la volatilidad, las correlaciones y la penalización.

5.3. Validación temporal y comparación de modelos

La validación de origen móvil respeta el orden temporal, pero emplea cinco bloques con ventanas de entrenamiento superpuestas. Por ello, el error estándar de la regla 1-SE es una medida práctica de variabilidad y no un error estándar clásico. Otra grilla o una búsqueda adaptativa también podrían producir una penalización diferente.

La evaluación utiliza una sola muestra final y una referencia basada en la media del entrenamiento. Superarla no establece superioridad frente a mínimos cuadrados, réplicas por capitalización, carteras equiponderadas u otros métodos regularizados. Ventanas adicionales permitirían examinar la estabilidad en distintos regímenes de mercado.

5.4. Inferencia y estructura de los residuos

La comparación del MSE de prueba es descriptiva: no se aplicó una prueba formal de igualdad de capacidad de seguimiento ni se construyeron intervalos para la diferencia de errores. Los resultados favorecen la hipótesis de investigación, pero no constituyen un rechazo estadístico formal de la hipótesis nula.

Los residuos presentaron colas pesadas, dependencia temporal en sus cuadrados y autocorrelación lineal leve en prueba. Ridge estabiliza la media frente a la multicolinealidad, pero no modela la volatilidad condicional. La inferencia formal requeriría procedimientos robustos para series temporales o un modelo específico para la varianza.

Capítulo 6

Conclusiones

Esta investigación evaluó la capacidad de una regresión ridge para reproducir fuera de muestra el rendimiento diario contemporáneo del S&P 500 a partir de sus empresas componentes. La elevada cantidad de predictores y las correlaciones entre ellos justificaron el uso de regularización. Tras limpiar, transformar y alinear la base original, el modelo utilizó 487 predictores y 1 434 observaciones.

El parámetro de penalización se seleccionó mediante validación temporal de origen móvil y la regla de un error estándar, sin utilizar la muestra de prueba. Fuera de muestra, el modelo alcanzó un coeficiente de determinación de 0,8781 y una correlación de 0,9396 entre rendimientos observados y estimados. Además, redujo el error cuadrático medio en 87,82 % respecto de la referencia basada en la media del entrenamiento. Esta comparación descriptiva favorece la hipótesis de investigación y respalda la capacidad de seguimiento de ridge.

Los coeficientes principales y la presencia simultánea de variables estrechamente relacionadas muestran que ridge distribuye la contribución entre predictores redundantes. Aunque el desempeño fuera de muestra fue elevado, resultó inferior al ajuste de entrenamiento. Los residuos presentaron colas pesadas, dependencia temporal en su magnitud y autocorrelación lineal leve en prueba; por ello, los resultados aconsejan cautela en la inferencia y confirman que ridge no modela directamente la dinámica de la volatilidad.

En síntesis, ridge ofrece una alternativa sencilla y computacionalmente viable para seguir un índice con numerosos predictores correlacionados. Como extensiones se propone reconstruir la composición histórica y las ponderaciones oficiales del S&P 500, comparar otros métodos, incorporar restricciones de cartera y evaluar múltiples ventanas temporales. El estudio de capacidad predictiva futura requeriría un diseño distinto basado en variables rezagadas.

Bibliografía

[1] Chun, D., Kang, J., and Kim, J. (2024). Forecasting returns with machine learning and optimizing global portfolios: Evidence from the korean and U.S. stock markets. *Financial Innovation*, 10:124.

[2] Ding, Y., Peng, Q., Song, Z., and Chen, H. (2023). Variable selection and regularization via arbitrary rectangle-range generalized elastic net. *Statistics and Computing*, 33:72.

[3] Doukali, M., Kone, N., and Taamouti, A. (2026). A regularization approach to optimizing large portfolios under asymmetries in returns and risk attitudes. *Econometric Reviews*, 45(6):826–855.

[4] Friedman, J., Hastie, T., and Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1):1–22.

[5] Gehrig, T., S.ºgner, L., and Westerkamp, A. (2025). Extending the demand system approach to asset pricing. *Financial Markets and Portfolio Management*, 39:133–166.

[6] Ha, Y. S., Kang, J., Kim, J., and Chun, D. (2026). Machine learning-based portfolio optimization: Comparative analysis with the all-weather portfolio strategy. *Financial Innovation*, 12:112.

[7] Oliveira, D. C., Sandfelder, D., Fujita, A., Dong, X., and Cucuringu, M. (2026). Tactical asset allocation with macroeconomic regime detection. *Quantitative Finance*, 26(9):1465–1491.

[8] R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. Disponible en: https://www.R-project.org/.

[9] Ryan, J. A. and Ulrich, J. M. (2026). *quantmod: Quantitative Financial Modelling Framework*. Paquete de R. Disponible en: https://CRAN.R-project.org/package=quantmod.

[10] Scholz, M. (2025). Forecast combinations for benchmarks of long-term stock returns using machine learning methods. *Annals of Operations Research*, 352:583–612.

[11] TradingView (2026). Componentes del índice s&p 500. https://es.tradingview.com/symbols/SPX/components/. Consultado el 23 de septiembre de 2026.

[12] Vargas Jiménez, F. O. A. (2026). Regresión ridge s&p 500: código del proyecto. Repositorio de GitHub: https://github.com/FabianVJ97/Regresion-Ridge-S-P500. Consultado el 15 de octubre de 2026.

[13] Yahoo Finance (2026). Historical market data. https://finance.yahoo.com/. Consultado en septiembre de 2026.

Apéndice A

Listado de empresas del S&P 500

El presente apéndice contiene los nombres, símbolos bursátiles y sectores económicos de las 503 empresas identificadas como componentes del S&P 500 al momento de la extracción desde TradingView. La numeración corresponde al orden alfabético utilizado en la base original.

Cuadro A.1: Empresas componentes del índice S&P 500

N.	Símbolo	Empresa	Sector
1	MMM	3M Company	Producer Manufacturing
2	AOS	A. O. Smith Corporation	Producer Manufacturing
3	ABT	Abbott Laboratories	Health Technology
4	ABBV	AbbVie, Inc.	Health Technology
5	ACN	Accenture Plc Class A	Technology Services
6	ADBE	Adobe Inc.	Technology Services
7	AMD	Advanced Micro Devices, Inc.	Electronic Technology
8	AES	AES Corporation	Utilities
9	AFL	Aflac Incorporated	Finance
10	A	Agilent Technologies, Inc.	Health Technology
11	APD	Air Products and Chemicals, Inc.	Process Industries
12	ABNB	Airbnb, Inc. Class A	Consumer Services
13	AKAM	Akamai Technologies, Inc.	Technology Services
14	ALB	Albemarle Corporation	Process Industries
15	ARE	Alexandria Real Estate Equities, Inc.	Finance
16	ALGN	Align Technology, Inc.	Health Technology
17	ALLE	Allegion Public Limited Company	Consumer Durables
18	LNT	Alliant Energy Corporation	Utilities

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
19	ALL	Allstate Corporation	Finance
20	GOOGL	Alphabet Inc. Class A	Technology Services
21	GOOG	Alphabet Inc. Class C	Technology Services
22	MO	Altria Group, Inc.	Consumer Non-Durables
23	AMZN	Amazon.com, Inc.	Retail Trade
24	AMCR	Amcor PLC	Process Industries
25	AEE	Ameren Corporation	Utilities
26	AEP	American Electric Power Company, Inc.	Utilities
27	AXP	American Express Company	Finance
28	AIG	American International Group, Inc.	Finance
29	AMT	American Tower Corporation	Finance
30	AWK	American Water Works Company, Inc.	Utilities
31	AMP	Ameriprise Financial, Inc.	Finance
32	AME	AMETEK, Inc.	Producer Manufacturing
33	AMGN	Amgen Inc.	Health Technology
34	APH	Amphenol Corporation Class A	Electronic Technology
35	ADI	Analog Devices, Inc.	Electronic Technology
36	AON	Aon Plc Class A	Finance
37	APA	APA Corporation	Energy Minerals
38	APO	Apollo Global Management Inc	Finance
39	AAPL	Apple Inc.	Electronic Technology
40	AMAT	Applied Materials, Inc.	Producer Manufacturing
41	APP	AppLovin Corp. Class A	Technology Services
42	APTV	Aptiv PLC	Producer Manufacturing
43	ACGL	Arch Capital Group Ltd.	Finance
44	ADM	Archer-Daniels-Midland Company	Process Industries
45	ARES	Ares Management Corporation Class A	Finance
46	ANET	Arista Networks Inc	Electronic Technology
47	AJG	Arthur J. Gallagher & Co.	Finance
48	AIZ	Assurant, Inc.	Finance
49	T	AT&T Inc	Communications
50	ATO	Atmos Energy Corporation	Utilities
51	ADSK	Autodesk, Inc.	Technology Services
52	ADP	Automatic Data Processing, Inc.	Technology Services
53	AZO	AutoZone, Inc.	Retail Trade
54	AVY	Avery Dennison Corporation	Process Industries
55	AXON	Axon Enterprise Inc	Electronic Technology

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
56	BKR	Baker Hughes Company Class A	Industrial Services
57	BALL	Ball Corporation	Process Industries
58	BAC	Bank of America Corp	Finance
59	BNY	Bank of New York Mellon Corp	Finance
60	BAX	Baxter International Inc.	Health Technology
61	BDX	Becton, Dickinson and Company	Health Technology
62	BRK.B	Berkshire Hathaway Inc. Class B	Finance
63	BBY	Best Buy Co., Inc.	Retail Trade
64	TECH	Bio-Techne Corporation	Health Technology
65	BIIB	Biogen Inc.	Health Technology
66	BLK	BlackRock, Inc.	Finance
67	BX	Blackstone Inc.	Finance
68	XYZ	Block, Inc. Class A	Commercial Services
69	BE	Bloom Energy Corporation Class A	Electronic Technology
70	BA	Boeing Company	Electronic Technology
71	BKNG	Booking Holdings Inc.	Consumer Services
72	BSX	Boston Scientific Corporation	Health Technology
73	BMY	Bristol-Myers Squibb Company	Health Technology
74	AVGO	Broadcom Inc.	Electronic Technology
75	BR	Broadridge Financial Solutions, Inc.	Technology Services
76	BF.B	Brown-Forman Corporation Class B	Consumer Non-Durables
77	BRO	Brown & Brown, Inc.	Finance
78	BG	Bunge Global SA	Process Industries
79	BXP	BXP Inc	Finance
80	CHRW	C.H. Robinson Worldwide, Inc.	Transportation
81	CDNS	Cadence Design Systems, Inc.	Technology Services
82	CPT	Camden Property Trust	Finance
83	COF	Capital One Financial Corp	Finance
84	CAH	Cardinal Health, Inc.	Distribution Services
85	CCL	Carnival Corporation Ltd.	Consumer Services
86	CARR	Carrier Global Corp.	Producer Manufacturing
87	CVNA	Carvana Co. Class A	Retail Trade
88	CASY	Casey's General Stores, Inc.	Retail Trade
89	CAT	Caterpillar Inc.	Producer Manufacturing
90	CBOE	Cboe Global Markets Inc	Finance
91	CBRE	CBRE Group, Inc. Class A	Finance
92	CDW	CDW Corporation	Technology Services

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
93	COR	Cencora, Inc.	Distribution Services
94	CNC	Centene Corporation	Health Services
95	CNP	CenterPoint Energy, Inc.	Utilities
96	CF	CF Industries Holdings, Inc.	Process Industries
97	CRL	Charles River Laboratories International, Inc.	Commercial Services
98	SCHW	Charles Schwab Corp	Finance
99	CHTR	Charter Communications, Inc. Class A	Consumer Services
100	CVX	Chevron Corporation	Energy Minerals
101	CMG	Chipotle Mexican Grill, Inc.	Consumer Services
102	CB	Chubb Limited	Finance
103	CHD	Church & Dwight Co., Inc.	Consumer Non-Durables
104	CIEN	Ciena Corporation	Electronic Technology
105	CI	Cigna Group	Health Services
106	CINF	Cincinnati Financial Corporation	Finance
107	CTAS	Cintas Corporation	Commercial Services
108	CSCO	Cisco Systems, Inc.	Electronic Technology
109	C	Citigroup Inc.	Finance
110	CFG	Citizens Financial Group, Inc.	Finance
111	CLX	Clorox Company	Consumer Non-Durables
112	CME	CME Group Inc. Class A	Finance
113	CMS	CMS Energy Corporation	Utilities
114	KO	Coca-Cola Company	Consumer Non-Durables
115	CTSH	Cognizant Technology Solutions Corporation Class A	Technology Services
116	COHR	Coherent Corp.	Electronic Technology
117	COIN	Coinbase Global, Inc. Class A	Finance
118	CL	Colgate-Palmolive Company	Consumer Non-Durables
119	CMCSA	Comcast Corporation Class A	Consumer Services
120	FIX	Comfort Systems USA, Inc.	Industrial Services
121	COP	ConocoPhillips	Energy Minerals
122	ED	Consolidated Edison, Inc.	Utilities
123	STZ	Constellation Brands, Inc. Class A	Consumer Non-Durables
124	CEG	Constellation Energy Corporation	Utilities
125	COO	Cooper Companies, Inc.	Health Technology
126	CPRT	Copart, Inc.	Retail Trade
127	GLW	Corning Inc	Electronic Technology

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
128	CPAY	Corpay, Inc.	Commercial Services
129	CTVA	Corteva Inc	Process Industries
130	CSGP	CoStar Group, Inc.	Technology Services
131	COST	Costco Wholesale Corporation	Retail Trade
132	CRH	CRH public limited company	Non-Energy Minerals
133	CRWD	CrowdStrike Holdings, Inc. Class A	Technology Services
134	CCI	Crown Castle Inc.	Finance
135	CSX	CSX Corporation	Transportation
136	CMI	Cummins Inc.	Producer Manufacturing
137	CVS	CVS Health Corporation	Retail Trade
138	DHI	D.R. Horton, Inc.	Consumer Durables
139	DHR	Danaher Corporation	Health Technology
140	DRI	Darden Restaurants, Inc.	Consumer Services
141	DDOG	Datadog, Inc. Class A	Technology Services
142	DVA	DaVita Inc.	Health Services
143	DECK	Deckers Outdoor Corporation	Consumer Non-Durables
144	DE	Deere & Company	Producer Manufacturing
145	DELL	Dell Technologies, Inc. Class C	Electronic Technology
146	DAL	Delta Air Lines, Inc.	Transportation
147	DVN	Devon Energy Corporation	Energy Minerals
148	DXCM	DexCom, Inc.	Health Technology
149	FANG	Diamondback Energy, Inc.	Energy Minerals
150	DLR	Digital Realty Trust, Inc.	Finance
151	DG	Dollar General Corporation	Retail Trade
152	DLTR	Dollar Tree, Inc.	Retail Trade
153	D	Dominion Energy Inc	Utilities
154	DPZ	Domino's Pizza, Inc.	Consumer Services
155	DASH	DoorDash, Inc. Class A	Transportation
156	DOV	Dover Corporation	Producer Manufacturing
157	DOW	Dow, Inc.	Process Industries
158	DTE	DTE Energy Company	Utilities
159	DUK	Duke Energy Corporation	Utilities
160	DD	DuPont de Nemours, Inc.	Process Industries
161	ETN	Eaton Corp. Plc	Producer Manufacturing
162	EBAY	eBay Inc.	Retail Trade
163	ECHO	EchoStar Corporation Class A	Communications
164	ECL	Ecolab Inc.	Process Industries

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
165	EIX	Edison International	Utilities
166	EW	Edwards Lifesciences Corporation	Health Technology
167	ELV	Elevance Health, Inc.	Health Services
168	LLY	Eli Lilly and Company	Health Technology
169	EME	EMCOR Group, Inc.	Industrial Services
170	EMR	Emerson Electric Co.	Electronic Technology
171	ETR	Entergy Corporation	Utilities
172	EOG	EOG Resources, Inc.	Energy Minerals
173	EQT	EQT Corporation	Energy Minerals
174	EFX	Equifax Inc.	Commercial Services
175	EQIX	Equinix, Inc.	Finance
176	ERIE	Erie Indemnity Company Class A	Finance
177	ESS	Essex Property Trust, Inc.	Finance
178	EL	Estee Lauder Companies Inc. Class A	Consumer Non-Durables
179	EG	Everest Group, Ltd.	Finance
180	EVRG	Evergy, Inc.	Utilities
181	P	Everpure, Inc. Class A	Electronic Technology
182	ES	Eversource Energy	Utilities
183	EXC	Exelon Corporation	Utilities
184	EXE	Expand Energy Corporation	Energy Minerals
185	EXPE	Expedia Group, Inc.	Consumer Services
186	EXPD	Expeditors International of Washington, Inc.	Transportation
187	EXR	Extra Space Storage Inc.	Finance
188	XOM	Exxonmobil Holdings Corporation	Energy Minerals
189	FFIV	F5, Inc.	Technology Services
190	FDS	FactSet Research Systems Inc.	Commercial Services
191	FICO	Fair Isaac Corporation	Commercial Services
192	FAST	Fastenal Company	Distribution Services
193	FRT	Federal Realty Investment Trust	Finance
194	FDX	FedEx Corporation	Transportation
195	FDXF	FedEx Freight Holding Company, Inc.	Transportation
196	FERG	Ferguson Enterprises Inc.	Distribution Services
197	FIS	Fidelity National Information Services, Inc.	Technology Services
198	FITB	Fifth Third Bancorp	Finance
199	FSLR	First Solar, Inc.	Electronic Technology

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
200	FE	FirstEnergy Corp.	Utilities
201	FISV	Fiserv, Inc.	Commercial Services
202	FLEX	Flex Ltd	Electronic Technology
203	F	Ford Motor Company	Consumer Durables
204	FTNT	Fortinet, Inc.	Technology Services
205	FTV	Fortive Corp.	Electronic Technology
206	FOXA	Fox Corporation Class A	Consumer Services
207	FOX	Fox Corporation Class B	Consumer Services
208	BEN	Franklin Templeton, Inc.	Finance
209	FCX	Freeport-McMoRan, Inc.	Non-Energy Minerals
210	GRMN	Garmin Ltd.	Electronic Technology
211	IT	Gartner, Inc.	Technology Services
212	GE	GE Aerospace	Electronic Technology
213	GEHC	GE Healthcare Technologies Inc.	Health Technology
214	GEV	GE Vernova Inc.	Producer Manufacturing
215	GEN	Gen Digital Inc.	Technology Services
216	GNRC	Generac Holdings Inc.	Producer Manufacturing
217	GD	General Dynamics Corporation	Electronic Technology
218	GIS	General Mills, Inc.	Consumer Non-Durables
219	GM	General Motors Company	Consumer Durables
220	GPC	Genuine Parts Company	Distribution Services
221	GILD	Gilead Sciences, Inc.	Health Technology
222	GPN	Global Payments Inc.	Finance
223	GL	Globe Life Inc.	Finance
224	GDDY	GoDaddy, Inc. Class A	Technology Services
225	GS	Goldman Sachs Group, Inc.	Finance
226	HAL	Halliburton Company	Industrial Services
227	HIG	Hartford Insurance Group, Inc.	Finance
228	HAS	Hasbro, Inc.	Consumer Durables
229	HCA	HCA Healthcare Inc	Health Services
230	DOC	Healthpeak Properties, Inc.	Finance
231	HSIC	Henry Schein, Inc.	Distribution Services
232	HSY	Hershey Company	Consumer Non-Durables
233	HPE	Hewlett Packard Enterprise Co.	Electronic Technology
234	HLT	Hilton Worldwide Holdings Inc.	Consumer Services
235	HD	Home Depot, Inc.	Retail Trade
236	HONA	Honeywell Aerospace Inc	Electronic Technology

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
237	HON	Honeywell International Inc.	Producer Manufacturing
238	HRL	Hormel Foods Corporation	Consumer Non-Durables
239	HST	Host Hotels & Resorts, Inc.	Finance
240	HWM	Howmet Aerospace Inc.	Electronic Technology
241	HPQ	HP Inc.	Technology Services
242	HUBB	Hubbell Incorporated	Producer Manufacturing
243	HUM	Humana Inc.	Health Services
244	HBAN	Huntington Bancshares Incorporated	Finance
245	HII	Huntington Ingalls Industries, Inc.	Electronic Technology
246	IEX	IDEX Corporation	Producer Manufacturing
247	IDXX	IDEXX Laboratories, Inc.	Health Technology
248	ITW	Illinois Tool Works Inc.	Producer Manufacturing
249	ILMN	Illumina, Inc.	Health Technology
250	INCY	Incyte Corporation	Health Technology
251	IR	Ingersoll Rand Inc.	Producer Manufacturing
252	PODD	Insulet Corporation	Health Technology
253	INTC	Intel Corporation	Electronic Technology
254	IBKR	Interactive Brokers Group, Inc. Class A	Finance
255	ICE	Intercontinental Exchange, Inc.	Finance
256	IBM	International Business Machines Corporation	Technology Services
257	IFF	International Flavors & Fragrances Inc.	Consumer Non-Durables
258	IP	International Paper Company	Process Industries
259	INTU	Intuit Inc.	Technology Services
260	ISRG	Intuitive Surgical, Inc.	Health Technology
261	IVZ	Invesco Ltd.	Finance
262	INVH	Invitation Homes, Inc.	Finance
263	IQV	IQVIA Holdings Inc	Health Technology
264	IRM	Iron Mountain, Inc.	Finance
265	JBHT	J.B. Hunt Transport Services, Inc.	Transportation
266	SJM	J.M. Smucker Company	Consumer Non-Durables
267	JBL	Jabil Inc.	Producer Manufacturing
268	JKHY	Jack Henry & Associates, Inc.	Technology Services
269	J	Jacobs Solutions Inc.	Technology Services
270	JNJ	Johnson	
	Johnson	Health Technology	
271	JCI	Johnson Controls International plc	Producer Manufacturing

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
272	JPM	JPMorgan Chase & Co.	Finance
273	KVUE	Kenvue, Inc.	Consumer Non-Durables
274	KDP	Keurig Dr Pepper Inc.	Consumer Non-Durables
275	KEY	KeyCorp	Finance
276	KEYS	Keysight Technologies Inc	Electronic Technology
277	KMB	Kimberly-Clark Corporation	Consumer Non-Durables
278	KIM	Kimco Realty Corporation	Finance
279	KMI	Kinder Morgan Inc Class P	Industrial Services
280	KKR	KKR & Co Inc	Finance
281	KLAC	KLA Corporation	Electronic Technology
282	KHC	Kraft Heinz Company	Consumer Non-Durables
283	KR	Kroger Co.	Retail Trade
284	LHX	L3Harris Technologies Inc	Electronic Technology
285	LH	Labcorp Holdings Inc.	Health Services
286	LRCX	Lam Research Corporation	Producer Manufacturing
287	LVS	Las Vegas Sands Corp.	Consumer Services
288	LDOS	Leidos Holdings, Inc.	Technology Services
289	LEN	Lennar Corporation Class A	Consumer Durables
290	LII	Lennox International Inc.	Producer Manufacturing
291	LIN	Linde plc	Process Industries
292	LYV	Live Nation Entertainment, Inc.	Consumer Services
293	LMT	Lockheed Martin Corporation	Electronic Technology
294	L	Loews Corporation	Finance
295	LOW	Lowe's Companies, Inc.	Retail Trade
296	LULU	lululemon athletica inc.	Consumer Non-Durables
297	LITE	Lumentum Holdings, Inc.	Producer Manufacturing
298	LYB	LyondellBasell Industries NV	Process Industries
299	MTB	M&T Bank Corporation	Finance
300	MPC	Marathon Petroleum Corporation	Energy Minerals
301	MAR	Marriott International, Inc. Class A	Consumer Services
302	MRSH	Marsh & McLennan Companies, Inc.	Finance
303	MLM	Martin Marietta Materials, Inc.	Non-Energy Minerals
304	MRVL	Marvell Technology, Inc.	Electronic Technology
305	MAS	Masco Corporation	Producer Manufacturing
306	MA	Mastercard Incorporated Class A	Finance
307	MKC	McCormick & Company, Incorporated	Consumer Non-Durables
308	MCD	McDonald's Corporation	Consumer Services

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
309	MCK	McKesson Corporation	Distribution Services
310	MDT	Medtronic Plc	Health Technology
311	MRK	Merck & Co., Inc.	Health Technology
312	META	Meta Platforms Inc Class A	Technology Services
313	MET	MetLife, Inc.	Finance
314	MTD	Mettler-Toledo International Inc.	Health Technology
315	MGM	MGM Resorts International	Consumer Services
316	MCHP	Microchip Technology Incorporated	Electronic Technology
317	MU	Micron Technology, Inc.	Electronic Technology
318	MSFT	Microsoft Corporation	Technology Services
319	MAA	Mid-America Apartment Communities, Inc.	Finance
320	MRNA	Moderna, Inc.	Health Technology
321	MDLZ	Mondelez International, Inc. Class A	Consumer Non-Durables
322	MPWR	Monolithic Power Systems, Inc.	Electronic Technology
323	MNST	Monster Beverage Corporation	Consumer Non-Durables
324	MCO	Moody's Corporation	Commercial Services
325	MS	Morgan Stanley	Finance
326	MOS	Mosaic Company	Process Industries
327	MSI	Motorola Solutions, Inc.	Electronic Technology
328	MSCI	MSCI Inc. Class A	Commercial Services
329	NDAQ	Nasdaq, Inc.	Finance
330	NTAP	NetApp, Inc.	Electronic Technology
331	NFLX	Netflix, Inc.	Technology Services
332	NEM	Newmont Corporation	Non-Energy Minerals
333	NWSA	News Corporation Class A	Consumer Services
334	NWS	News Corporation Class B	Consumer Services
335	NEE	NextEra Energy, Inc.	Utilities
336	NKE	NIKE, Inc. Class B	Consumer Non-Durables
337	NI	NiSource Inc	Utilities
338	NDSN	Nordson Corporation	Producer Manufacturing
339	NSC	Norfolk Southern Corporation	Transportation
340	NTRS	Northern Trust Corporation	Finance
341	NOC	Northrop Grumman Corp.	Electronic Technology
342	NCLH	Norwegian Cruise Line Holdings Ltd.	Consumer Services
343	NRG	NRG Energy, Inc.	Utilities
344	NUE	Nucor Corporation	Non-Energy Minerals

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
345	NVDA	NVIDIA Corporation	Electronic Technology
346	NVR	NVR, Inc.	Consumer Durables
347	NXPI	NXP Semiconductors NV	Electronic Technology
348	ORLY	O'Reilly Automotive, Inc.	Retail Trade
349	OXY	Occidental Petroleum Corporation	Energy Minerals
350	ODFL	Old Dominion Freight Line, Inc.	Transportation
351	OMC	Omnicom Group Inc	Commercial Services
352	ON	ON Semiconductor Corporation	Electronic Technology
353	OKE	ONEOK, Inc.	Industrial Services
354	ORCL	Oracle Corporation	Technology Services
355	OTIS	Otis Worldwide Corporation	Industrial Services
356	PCAR	PACCAR Inc	Producer Manufacturing
357	PKG	Packaging Corporation of America	Process Industries
358	PLTR	Palantir Technologies Inc. Class A	Technology Services
359	PANW	Palo Alto Networks, Inc.	Technology Services
360	PSKY	Paramount Skydance Corporation Class B	Consumer Services
361	PH	Parker-Hannifin Corporation	Producer Manufacturing
362	PAYX	Paychex, Inc.	Technology Services
363	PYPL	PayPal Holdings, Inc.	Commercial Services
364	PNR	Pentair plc	Producer Manufacturing
365	PEP	PepsiCo, Inc.	Consumer Non-Durables
366	PFE	Pfizer Inc.	Health Technology
367	PCG	PG&E Corporation	Utilities
368	PM	Philip Morris International Inc.	Consumer Non-Durables
369	PSX	Phillips 66	Energy Minerals
370	PNW	Pinnacle West Capital Corp	Utilities
371	PNC	PNC Financial Services Group, Inc.	Finance
372	PPG	PPG Industries, Inc.	Process Industries
373	PPL	PPL Corporation	Utilities
374	PFG	Principal Financial Group, Inc.	Finance
375	PG	Procter & Gamble Company	Consumer Non-Durables
376	PGR	Progressive Corporation	Finance
377	PLD	Prologis, Inc.	Finance
378	PRU	Prudential Financial, Inc.	Finance
379	PTC	PTC Inc.	Technology Services
380	PEG	Public Service Enterprise Group Inc	Utilities
381	PSA	Public Storage	Finance

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
382	PHM	PulteGroup, Inc.	Consumer Durables
383	Q	Qnity Electronics, Inc.	Electronic Technology
384	QCOM	QUALCOMM Incorporated	Electronic Technology
385	PWR	Quanta Services, Inc.	Industrial Services
386	DGX	Quest Diagnostics Incorporated	Health Services
387	RL	Ralph Lauren Corporation Class A	Consumer Non-Durables
388	RJF	Raymond James Financial, Inc.	Finance
389	O	Realty Income Corporation	Finance
390	RDDT	Reddit, Inc. Class A	Technology Services
391	REG	Regency Centers Corporation	Finance
392	REGN	Regeneron Pharmaceuticals, Inc.	Health Technology
393	RF	Regions Financial Corporation	Finance
394	RSG	Republic Services, Inc.	Industrial Services
395	RMD	ResMed Inc.	Health Technology
396	RVTY	Revvity, Inc.	Health Technology
397	HOOD	Robinhood Markets, Inc. Class A	Finance
398	ROK	Rockwell Automation, Inc.	Producer Manufacturing
399	ROL	Rollins, Inc.	Commercial Services
400	ROP	Roper Technologies, Inc.	Technology Services
401	ROST	Ross Stores, Inc.	Retail Trade
402	RCL	Royal Caribbean Group	Consumer Services
403	RTX	RTX Corporation	Electronic Technology
404	SPGI	S&P Global, Inc.	Commercial Services
405	CRM	Salesforce, Inc.	Technology Services
406	SNDK	Sandisk Corporation	Electronic Technology
407	SBAC	SBA Communications Corp. Class A	Finance
408	STX	Seagate Technology Holdings PLC	Electronic Technology
409	SRE	Sempra	Utilities
410	NOW	ServiceNow, Inc.	Technology Services
411	SHW	Sherwin-Williams Company	Process Industries
412	SPG	Simon Property Group, Inc.	Finance
413	SWKS	Skyworks Solutions, Inc.	Electronic Technology
414	SLB	SLB Limited	Industrial Services
415	SW	Smurfit Westrock PLC	Process Industries
416	SNA	Snap-on Incorporated	Consumer Durables
417	SOLV	Solventum Corporation	Health Services
418	SO	Southern Company	Utilities

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
419	LUV	Southwest Airlines Co.	Transportation
420	SWK	Stanley Black & Decker, Inc.	Consumer Durables
421	SBUX	Starbucks Corporation	Consumer Services
422	STT	State Street Corporation	Finance
423	STLD	Steel Dynamics, Inc.	Non-Energy Minerals
424	STE	STERIS plc	Health Technology
425	SYK	Stryker Corporation	Health Technology
426	SMCI	Super Micro Computer, Inc.	Electronic Technology
427	SYF	Synchrony Financial	Finance
428	SNPS	Synopsys, Inc.	Technology Services
429	SYY	Sysco Corporation	Distribution Services
430	TMUS	T-Mobile US, Inc.	Communications
431	TROW	T. Rowe Price Group, Inc.	Finance
432	TTWO	Take-Two Interactive Software, Inc.	Technology Services
433	TPR	Tapestry, Inc.	Retail Trade
434	TRGP	Targa Resources Corp.	Utilities
435	TGT	Target Corporation	Retail Trade
436	TEL	TE Connectivity plc	Electronic Technology
437	TDY	Teledyne Technologies Incorporated	Electronic Technology
438	TER	Teradyne, Inc.	Electronic Technology
439	TSLA	Tesla, Inc.	Consumer Durables
440	TXN	Texas Instruments Incorporated	Electronic Technology
441	TPL	Texas Pacific Land Corporation	Miscellaneous
442	TXT	Textron Inc.	Electronic Technology
443	TMO	Thermo Fisher Scientific Inc.	Health Technology
444	TJX	TJX Companies Inc	Retail Trade
445	TKO	TKO Group Holdings, Inc. Class A	Consumer Services
446	TSCO	Tractor Supply Company	Retail Trade
447	TT	Trane Technologies plc	Producer Manufacturing
448	TDG	TransDigm Group Incorporated	Electronic Technology
449	TRV	Travelers Companies, Inc.	Finance
450	TRMB	Trimble Inc.	Technology Services
451	TFC	Truist Financial Corporation	Finance
452	TYL	Tyler Technologies, Inc.	Technology Services
453	TSN	Tyson Foods, Inc. Class A	Consumer Non-Durables
454	USB	U.S. Bancorp	Finance
455	UBER	Uber Technologies, Inc.	Transportation

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
456	UDR	UDR, Inc.	Finance
457	ULTA	Ulta Beauty Inc.	Retail Trade
458	UNP	Union Pacific Corporation	Transportation
459	UAL	United Airlines Holdings, Inc.	Transportation
460	UPS	United Parcel Service, Inc. Class B	Transportation
461	URI	United Rentals, Inc.	Finance
462	UNH	UnitedHealth Group Incorporated	Health Services
463	UHS	Universal Health Services, Inc. Class B	Health Services
464	VLO	Valero Energy Corporation	Energy Minerals
465	VEEV	Veeva Systems Inc. Class A	Technology Services
466	VTR	Ventas, Inc.	Finance
467	VLTO	Veralto Corporation	Producer Manufacturing
468	VRSN	VeriSign, Inc.	Technology Services
469	VRSK	Verisk Analytics, Inc.	Technology Services
470	VZ	Verizon Communications Inc.	Communications
471	VRTX	Vertex Pharmaceuticals Incorporated	Health Technology
472	VRT	Vertiv Holdings Co. Class A	Electronic Technology
473	VTRS	Viatris, Inc.	Health Technology
474	VICI	VICI Properties Inc	Finance
475	V	Visa Inc. Class A	Finance
476	VST	Vistra Corp.	Utilities
477	VMRK	Vivmark Residential	Finance
478	VMC	Vulcan Materials Company	Non-Energy Minerals
479	WRB	W. R. Berkley Corporation	Finance
480	GWW	W.W. Grainger, Inc.	Distribution Services
481	WMT	Walmart Inc.	Retail Trade
482	DIS	Walt Disney Company	Consumer Services
483	WBD	Warner Bros. Discovery, Inc. Series A	Consumer Services
484	WM	Waste Management, Inc.	Industrial Services
485	WAT	Waters Corporation	Health Technology
486	WEC	WEC Energy Group Inc	Utilities
487	WFC	Wells Fargo & Company	Finance
488	WELL	Welltower Inc.	Finance
489	WST	West Pharmaceutical Services, Inc.	Health Technology
490	WDC	Western Digital Corporation	Electronic Technology
491	WAB	Westinghouse Air Brake Technologies Corporation	Producer Manufacturing

Continúa en la página siguiente

N.	Símbolo	Empresa	Sector
492	WY	Weyerhaeuser Company	Finance
493	WSM	Williams-Sonoma, Inc.	Retail Trade
494	WMB	Williams Companies, Inc.	Industrial Services
495	WTW	Willis Towers Watson Public Limited Company	Finance
496	WDAY	Workday, Inc. Class A	Technology Services
497	WYNN	Wynn Resorts, Limited	Consumer Services
498	XEL	Xcel Energy Inc.	Utilities
499	XYL	Xylem Inc.	Producer Manufacturing
500	YUM	Yum! Brands, Inc.	Consumer Services
501	ZBRA	Zebra Technologies Corporation Class A	Electronic Technology
502	ZBH	Zimmer Biomet Holdings, Inc.	Health Technology
503	ZTS	Zoetis, Inc. Class A	Health Technology

Apéndice B

Distribución de empresas por sector económico

El sector es una variable cualitativa nominal que describe la actividad económica principal de cada empresa que compone el S&P 500. Las 503 empresas consideradas se distribuyen entre 20 sectores distintos. La Tabla B.1 presenta su distribución de frecuencias.

Cuadro B.1: Distribución de frecuencias según sector económico

Categoría	f_i	h_i	**Porcentaje (%)**
Commercial Services	14	0.028	2.78
Communications	4	0.008	0.80
Consumer Durables	11	0.022	2.19
Consumer Non-Durables	28	0.056	5.57
Consumer Services	28	0.056	5.57
Distribution Services	9	0.018	1.79
Electronic Technology	57	0.113	11.33
Energy Minerals	13	0.026	2.58
Finance	96	0.191	19.09
Health Services	11	0.022	2.19
Health Technology	42	0.083	8.35
Industrial Services	12	0.024	2.39
Miscellaneous	1	0.002	0.20
Non-Energy Minerals	7	0.014	1.39
Process Industries	20	0.040	3.98
Producer Manufacturing	33	0.066	6.56
Retail Trade	23	0.046	4.57
Technology Services	47	0.093	9.34
Transportation	15	0.030	2.98
Utilities	32	0.064	6.36
Total	**503**	**1.000**	**100.00**

Apéndice C

Material gráfico complementario

C.1. Distribución de los rendimientos

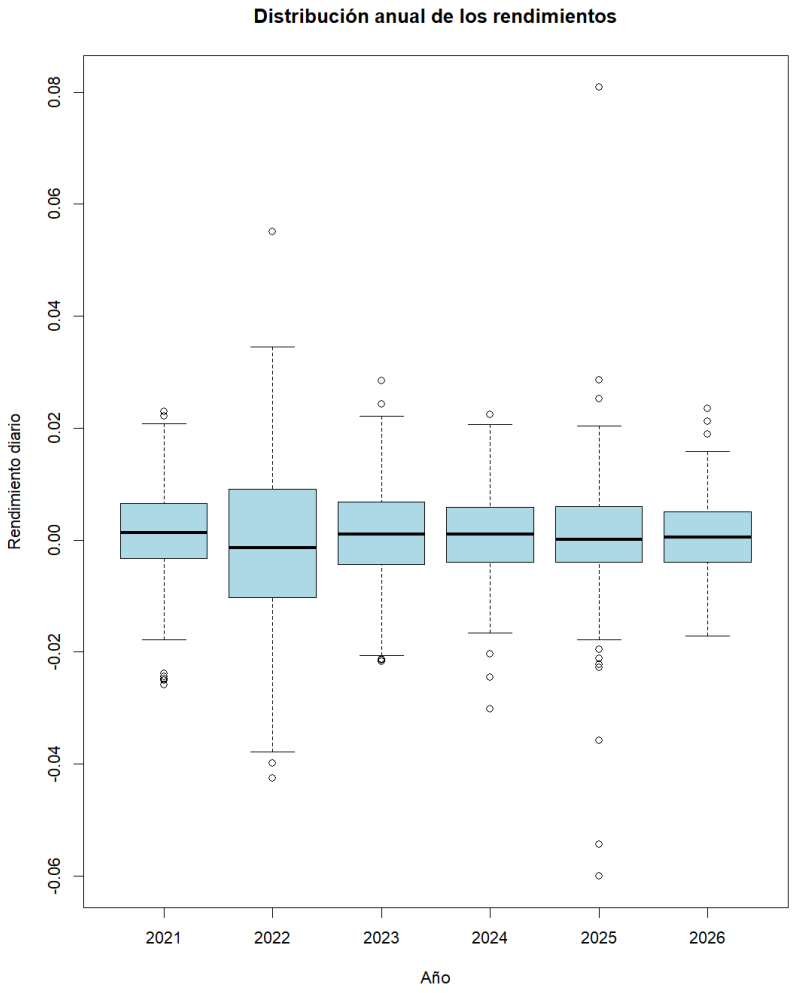
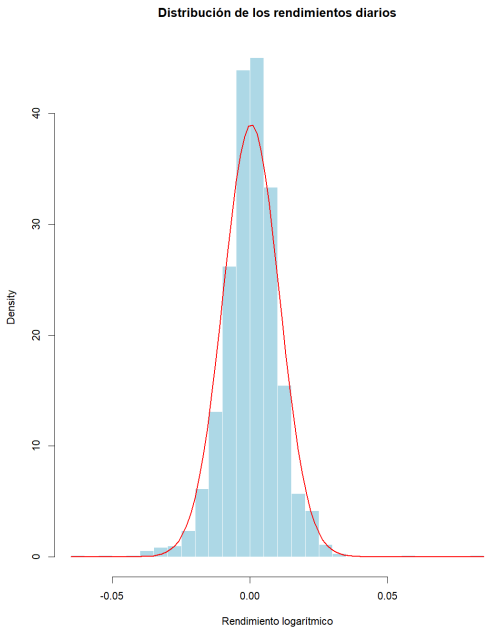
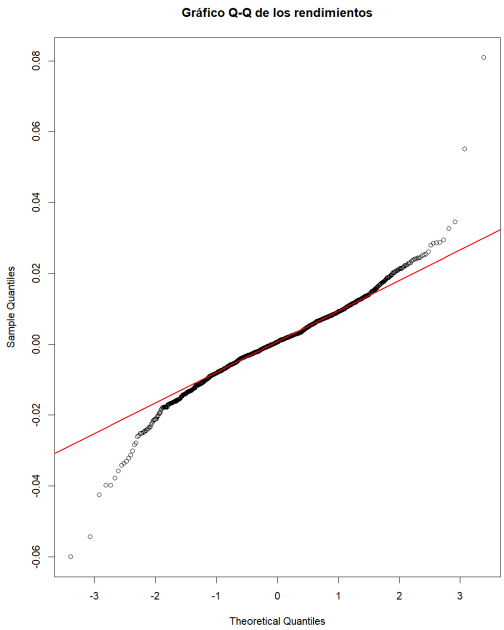


Figura C.1: Distribución anual de los rendimientos diarios



(a) Distribución de los rendimientos diarios



(b) Gráfico Q–Q de los rendimientos

Figura C.2: Análisis gráfico de la distribución de los rendimientos diarios

C.2. Autocorrelación de los residuos

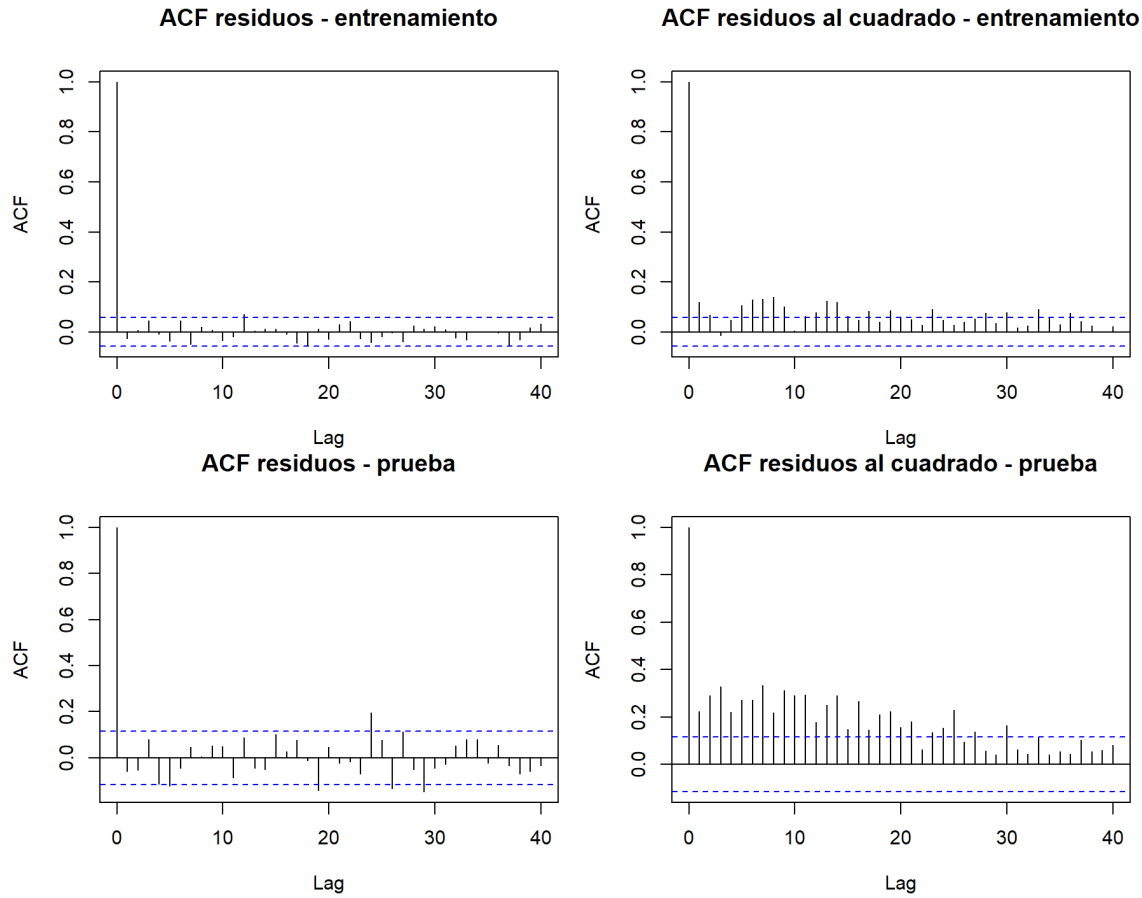


Figura C.3: Funciones de autocorrelación de los residuos y de los residuos al cuadrado